DTCC

2017第八届中国数据库技术大会

DATABASE TECHNOLOGY CONFERENCE CHINA 2017

腾讯CDB的核弹头-TXSQL

张青林

自我介绍

姓名：张青林

公司：Tencent

工作：MySQL kernel dev @ TEG.CDB

职责：性能优化、功能开发、线上问题定位及解决

邮箱：musazhang@tencent.com

Agenda

- ✓ TXSQL 概览
- ✓ TXSQL 内核研发
- ✓ TXSQL 云上实践
- ✓ TXSQL 未来发展发向

TXSQL 概览

✓ 什么是TXSQL

- ✓ TXSQL = Tencent MySQL
- ✓ 腾讯-TEG-基础架构部-CDB (Cloud DataBase)团队自研 MySQL 分支
- ✓ 腾讯云以及腾讯内部云DBaaS平台官方使用最多的MySQL版本

✓ 为什么有TXSQL

- ✓ MySQL- The most popular database
- ✓ 海量运营的挑战：超大规模、海量开发商、多种业务场景
- ✓ 促进开源数据库技术发展

TXSQL 概览(Cont.1)

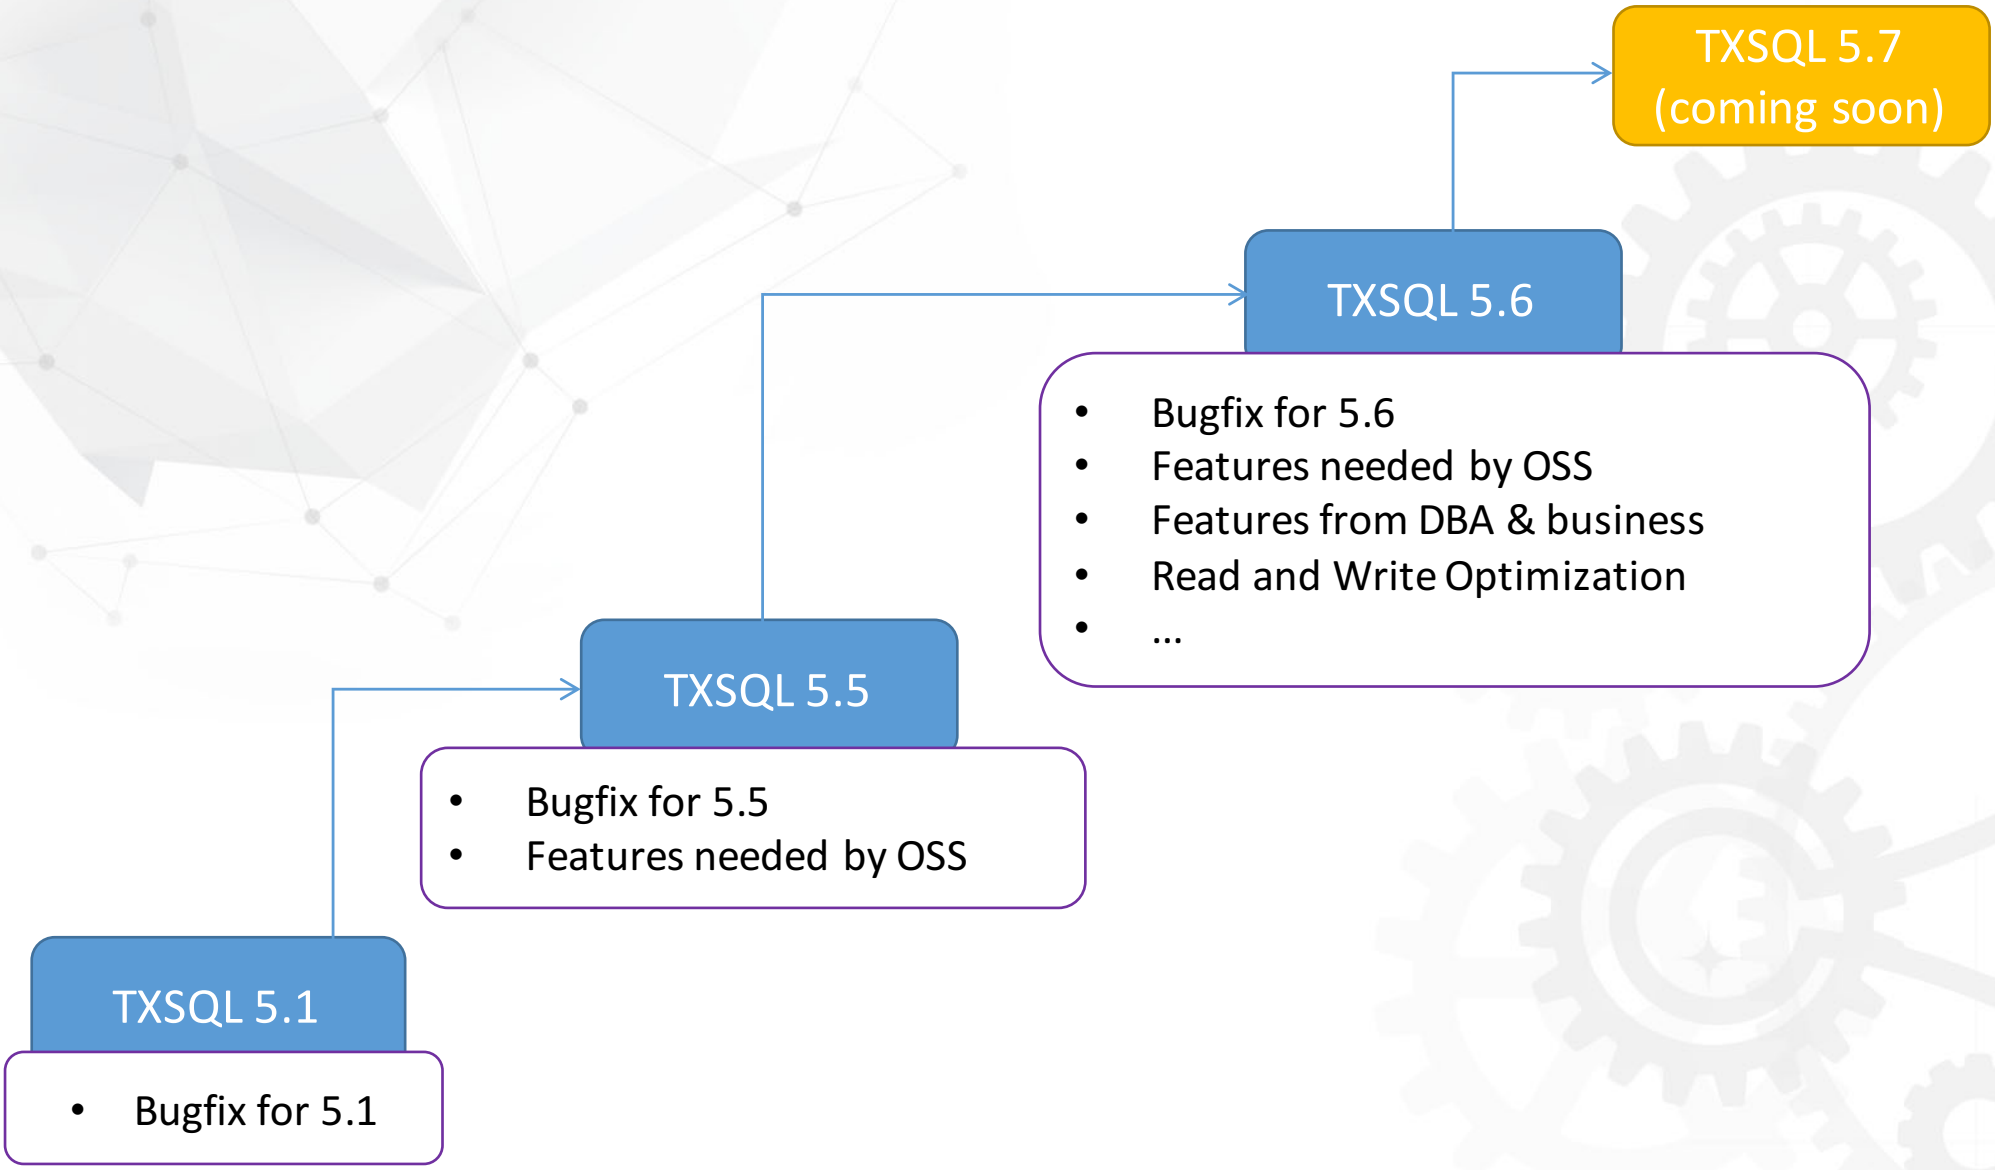

TXSQL 内核研发

- ✓ TXSQL 性能改进
- ✓ TXSQL 性能对比
- ✓ TXSQL 功能开发
- ✓ TXSQL 金融特性

TXSQL 性能改进

- ✓ TXSQL read view 优化
- ✓ TXSQL redo log 写优化
- ✓ TXSQL redo log 双缓冲区
- ✓ 隐式锁转化
- ✓ 主库 Lock_log 锁拆分

TXSQL read view 优化

read view 是什么

- low_limit_no, used for purge
- low_limit_id, trx whose trx_id >= low_limit_id is unvisible
- high_limit_id, trx whose trx_id < high_limit_id is visible

MySQL MVCC

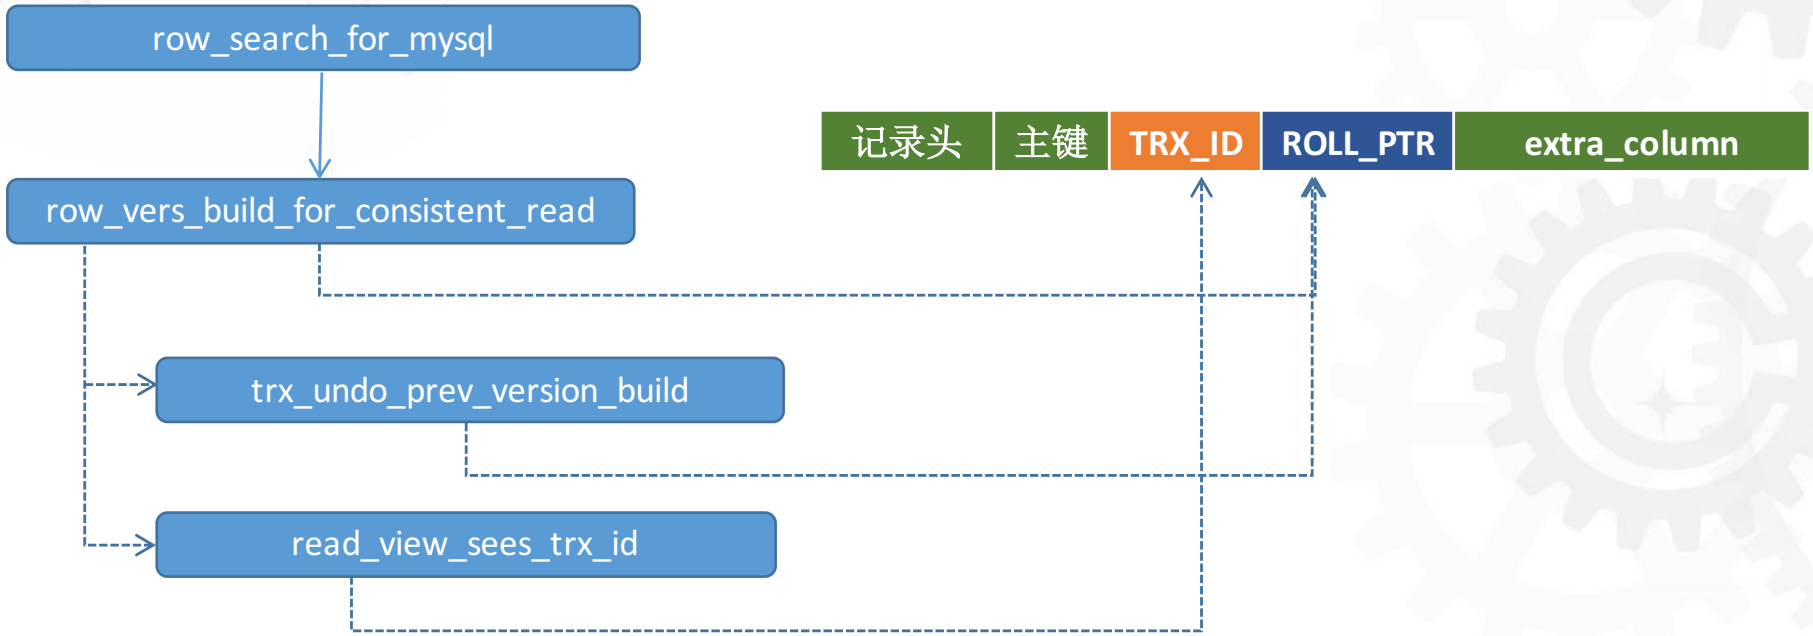

TXSQL read view 优化(Cont.1)

事务创建时的步骤如下：

1. 对 trx_sys->mutex 全局上锁；
2. 顺序扫描 trx_sys->rw_trx_list，对 read_view 中的元素分配内存并进行赋值；
3. 将新创建的 read_view 添加到有序列表 trx_sys->view_list中；
4. 释放 trx_sys->mutex 锁；

read view 创建存在的问题？

- ✓ 整个创建过程一直持有 trx_sys->mutex 锁；
- ✓ 需要遍历 trx_sys->trx_list (5.5) 或 trx_sys->rw_list (5.6)；
- ✓ read_view 的内存在每次创建中被分配，事务提交后被释放；
- ✓ 并发较大，活跃事务链表过长时，会在 trx_sys->mutex 上有较大的消耗；

TXSQL read view 优化(Cont.2)

TXSQL 解决上述问题的方法

TXSQL backport percona read view 相关修改到 TXSQL 中，并参照 5.7 的实现，在 5.6 中将 ro_trx_list 移除，主要包括以下修改：

- ✓ 在 trx_sys 下维护一个全局的事务ID的有序集合；
- ✓ 在 trx_sys 下维护一个有序的已分配序列号的事务列表，记录拥有最小序列号的事务，供 purge 时使用；
- ✓ 减少不必要的内存分配；
- ✓ 参照 5.7 的实现，在 5.6 中将 ro_trx_list 移除 ；

Redo log 优化背景

事务提交过程分析

MySQL 是典型的两阶段提交，事务在提交时，会首先将 redo log 落盘，然后落盘 binlog，其过程如下所示：

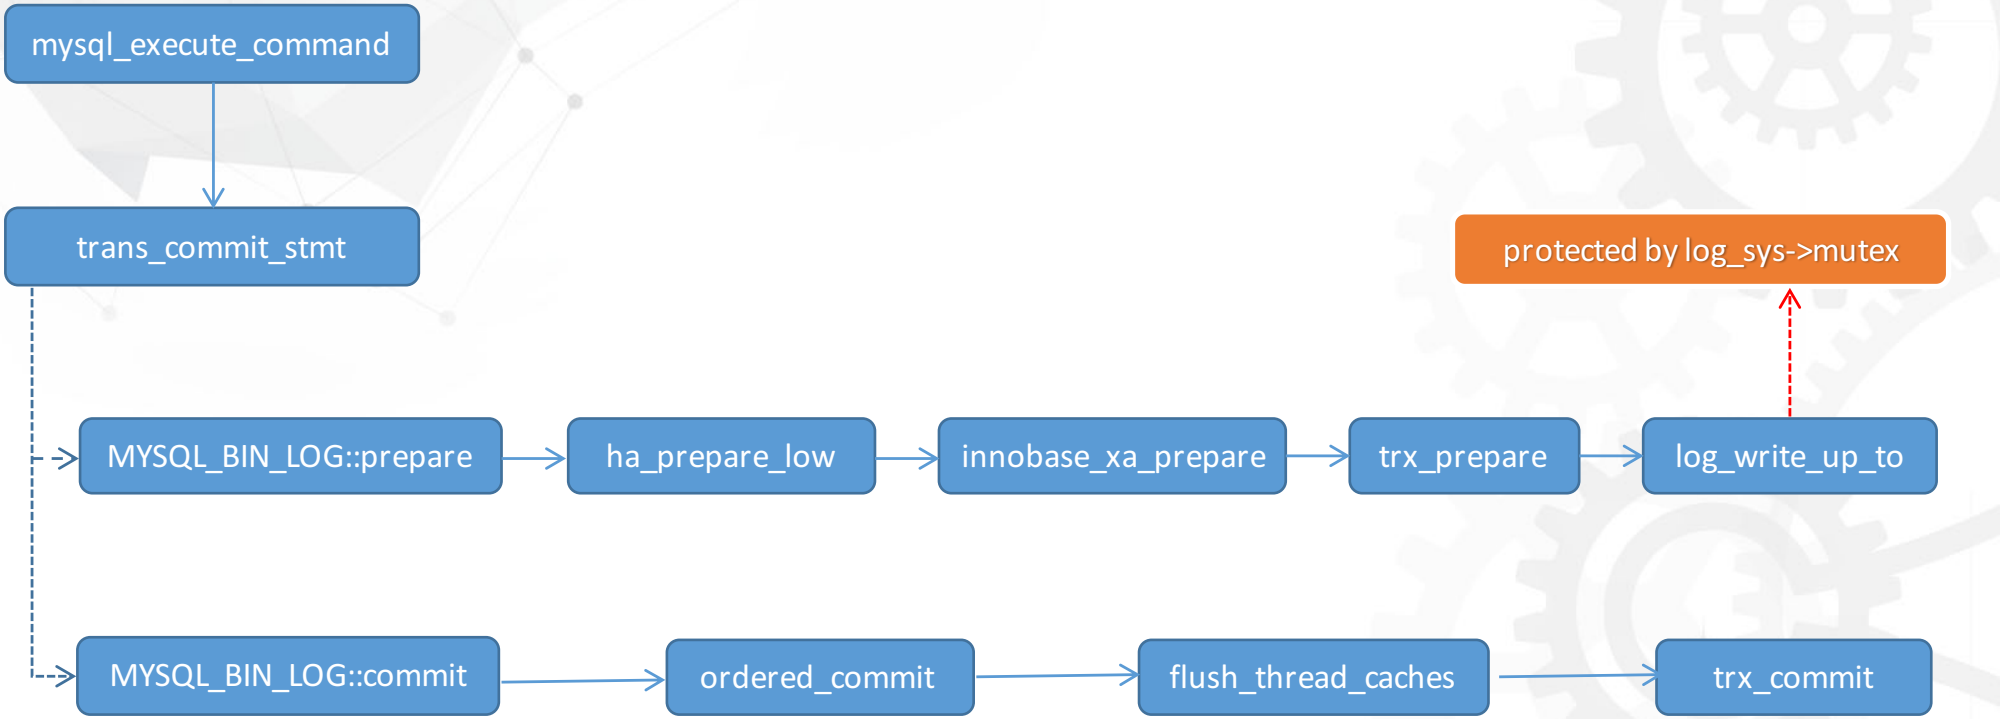

Redo log 优化背景(Cont.1)

TXSQL redo log 过程分析

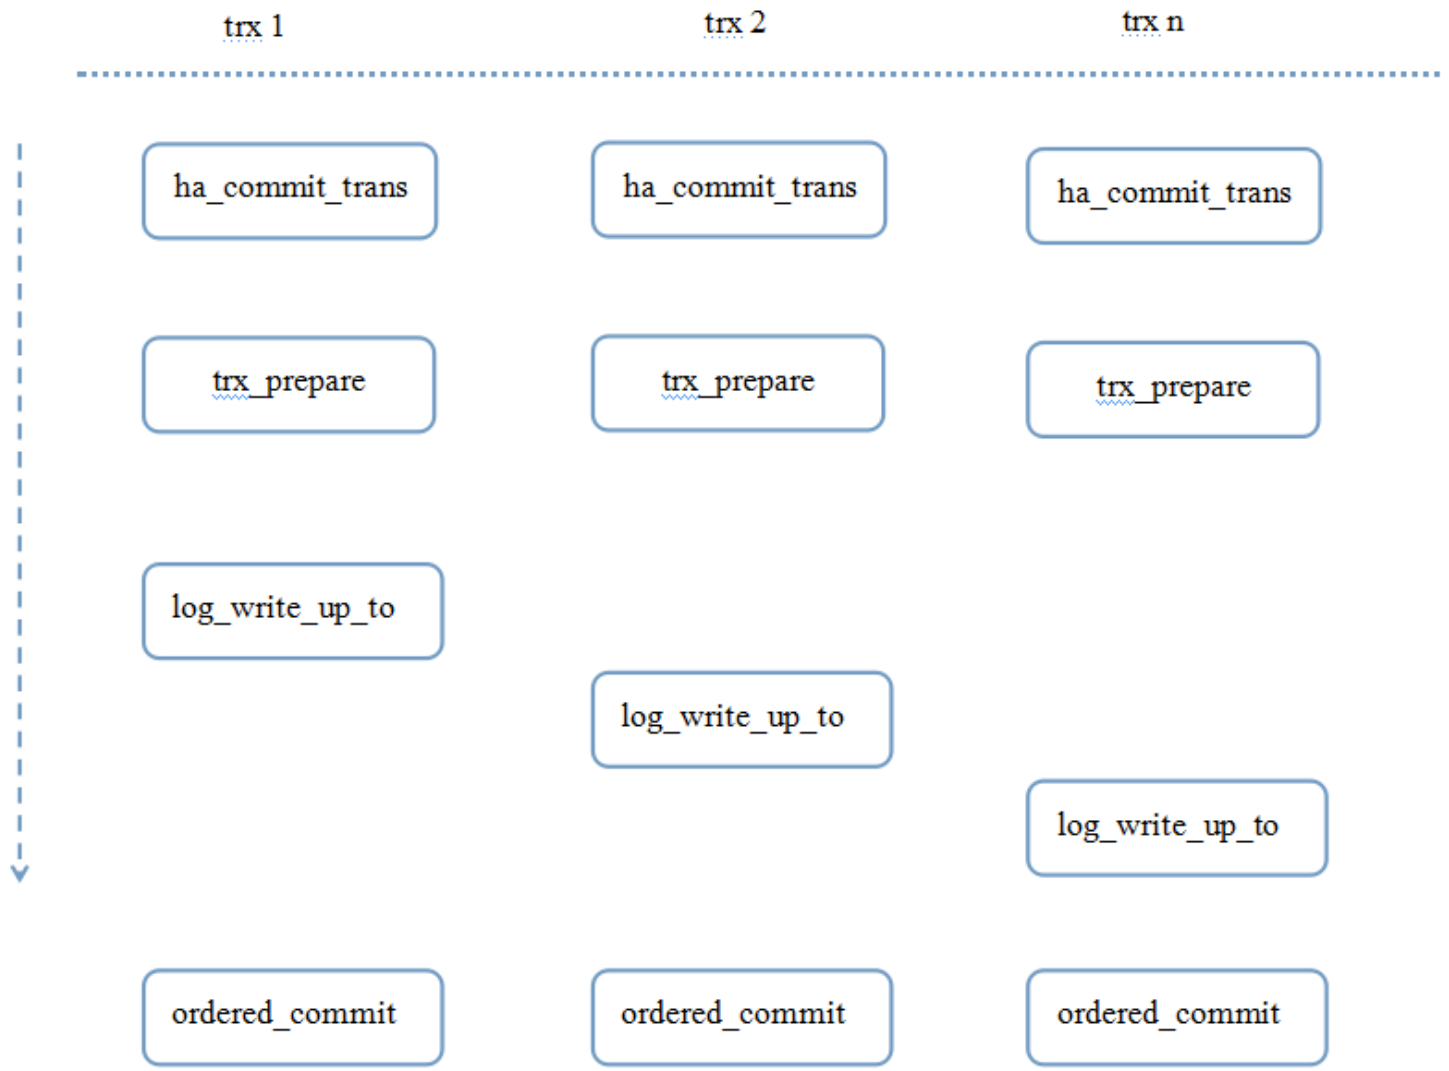

Redo log 优化背景(Cont.2)

MySQL 在 crash recovery 的过程如下：

1. 从 logfile 中读取最后的 checkpoint 位点信息，然后从该位置开始应用 redo 日志；
2. 从 undo 中读取回滚段并初始化读写事务链表 rw_trx_list，对 active 的事务进行回滚，详情可参考：trx_sys_init_at_db_start() 函数，对 prepared 事务进行保留，以在 binlog 文件读取后再决定是否 commit 或者 rollback；
3. 扫描最后的一个 binlog 文件，内部 XA 事务构建 xids 的集合 commit_list，外部 XA事务插入 xid_cache，详情可以参考：MYSQL_BIN_LOG::recover()；
4. 对于内部 XA事务，如果其 xid 存在于 内部读写事务链表 commit_list 中则进行提交，否则进行回滚；对于外部事务，则需要打印出相关日志，并等待命令以进行提交或回滚操作，其中内部 XA 事物与外部 XA 事务的区别为 xid 的名称；详情可参考 xarecover_handerton() 、get_my_xid() 函数。

TXSQL redo log 写优化 (bug#73202)

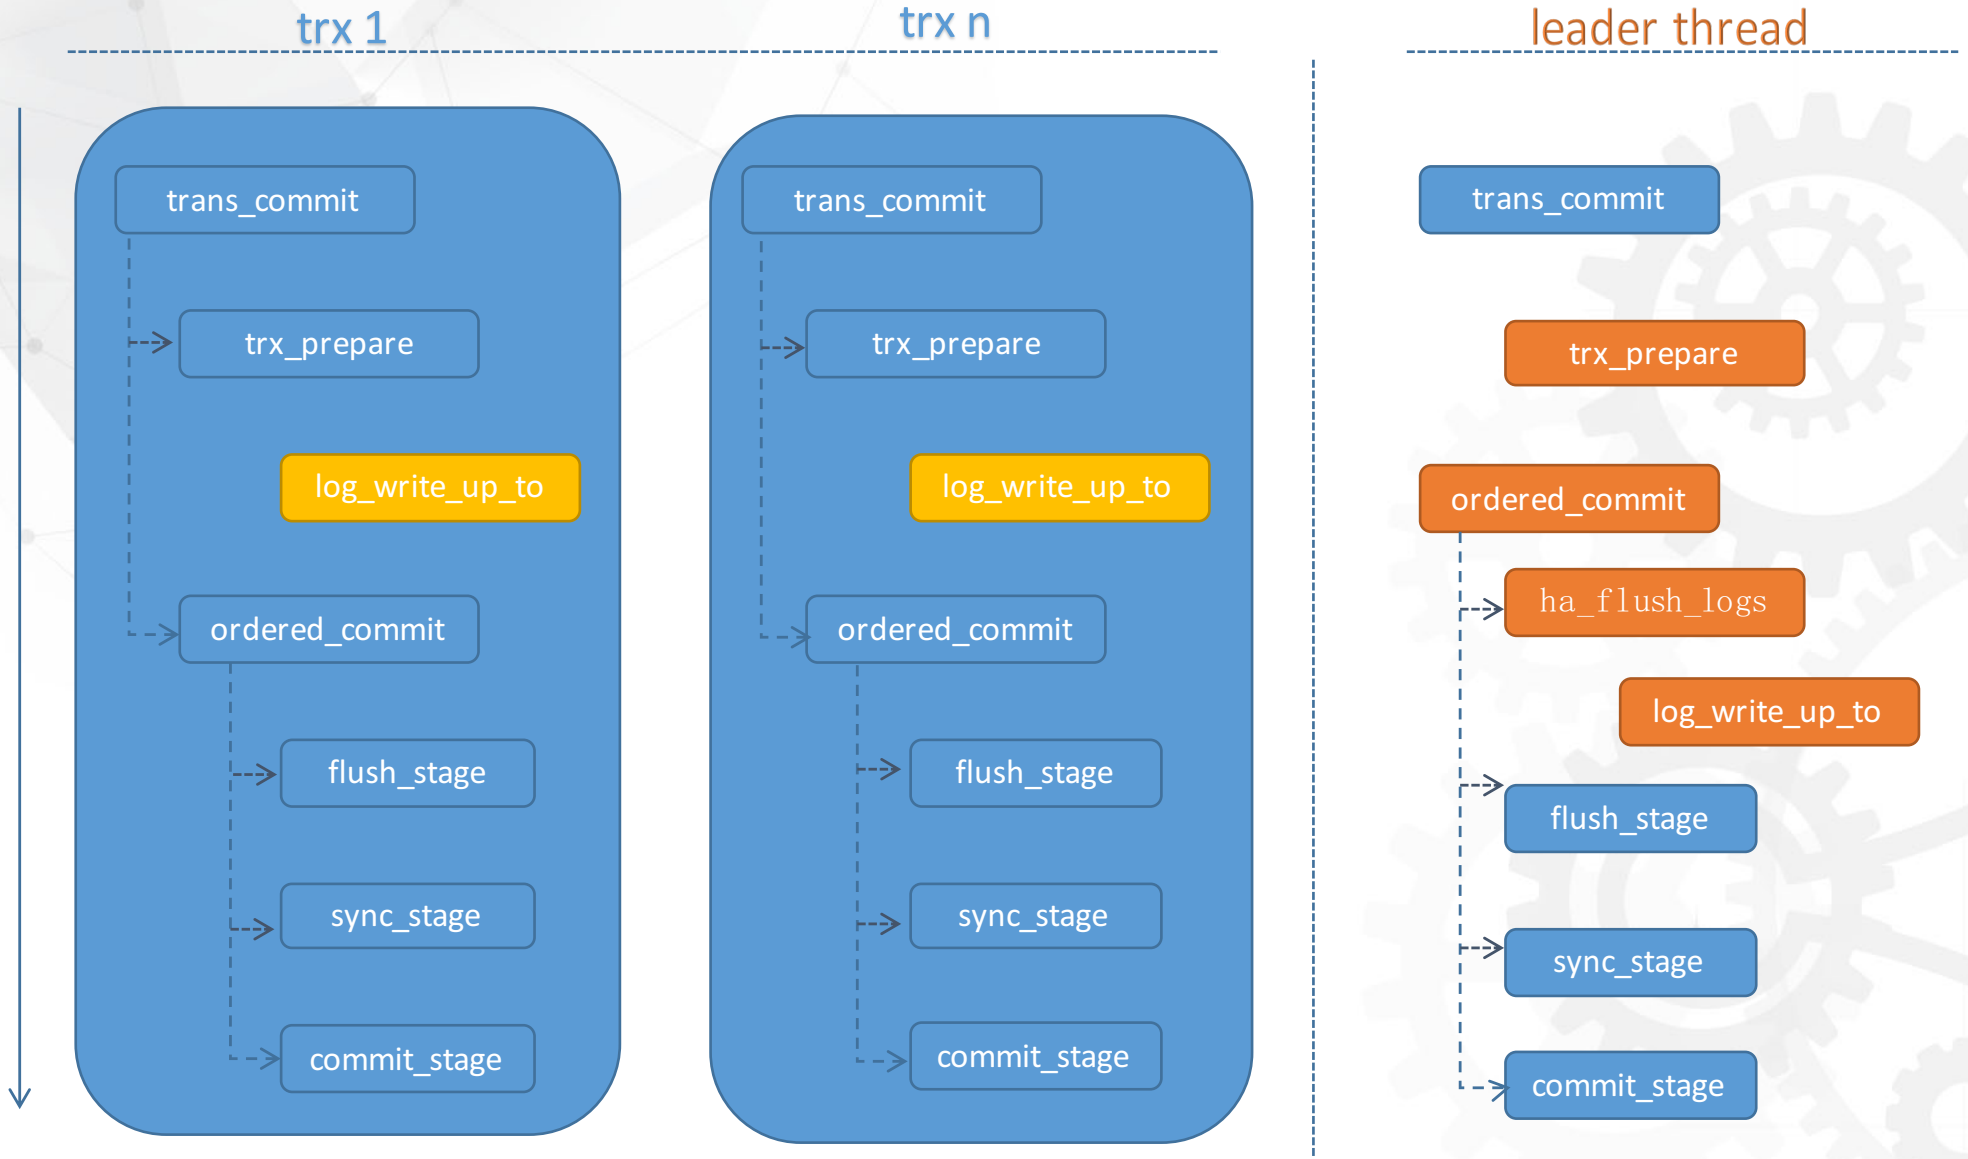

TXSQL redo log 双缓冲区

redo log 落盘的过程

redo log 在落盘期间，所有redo log 相关 read & write 处于阻塞状态

TXSQL redo log 双缓冲区(Cont.1)

redo log 落盘的过程的优化

redo log 在落盘期间，原有 redo log 相关 read & write 不受影响

TXSQL 隐式锁转化 (worklog#6899)

隐式锁转化的过程

1. 获取锁系统 lock_sys->mutex;
2. 获取事务系统 trx_sys->mutex;
3. 查找相关事务
4. 释放事务系统 trx_sys->mutex
5. 隐式锁转换
6. 释放锁系统 lock_sys->mutex;

隐式锁转化的优化

1. 获取事务系统 trx_sys->mutex;
2. 查找相关事务并进行引用计数
3. 释放事务系统 trx_sys->mutex
4. 获取锁系统 lock_sys->mutex;
5. 隐式锁转换并进行引用计数的调整
6. 释放锁系统 lock_sys->mutex;

其中，涉及的事务在引用计数不为零时，是不允许被销毁的，通过减少 lock_sys->mutex 的占用时间来提升性能；

主库 Lock_log 锁拆分

binlog 写线程 & binlog_sender 线程中的性能分析

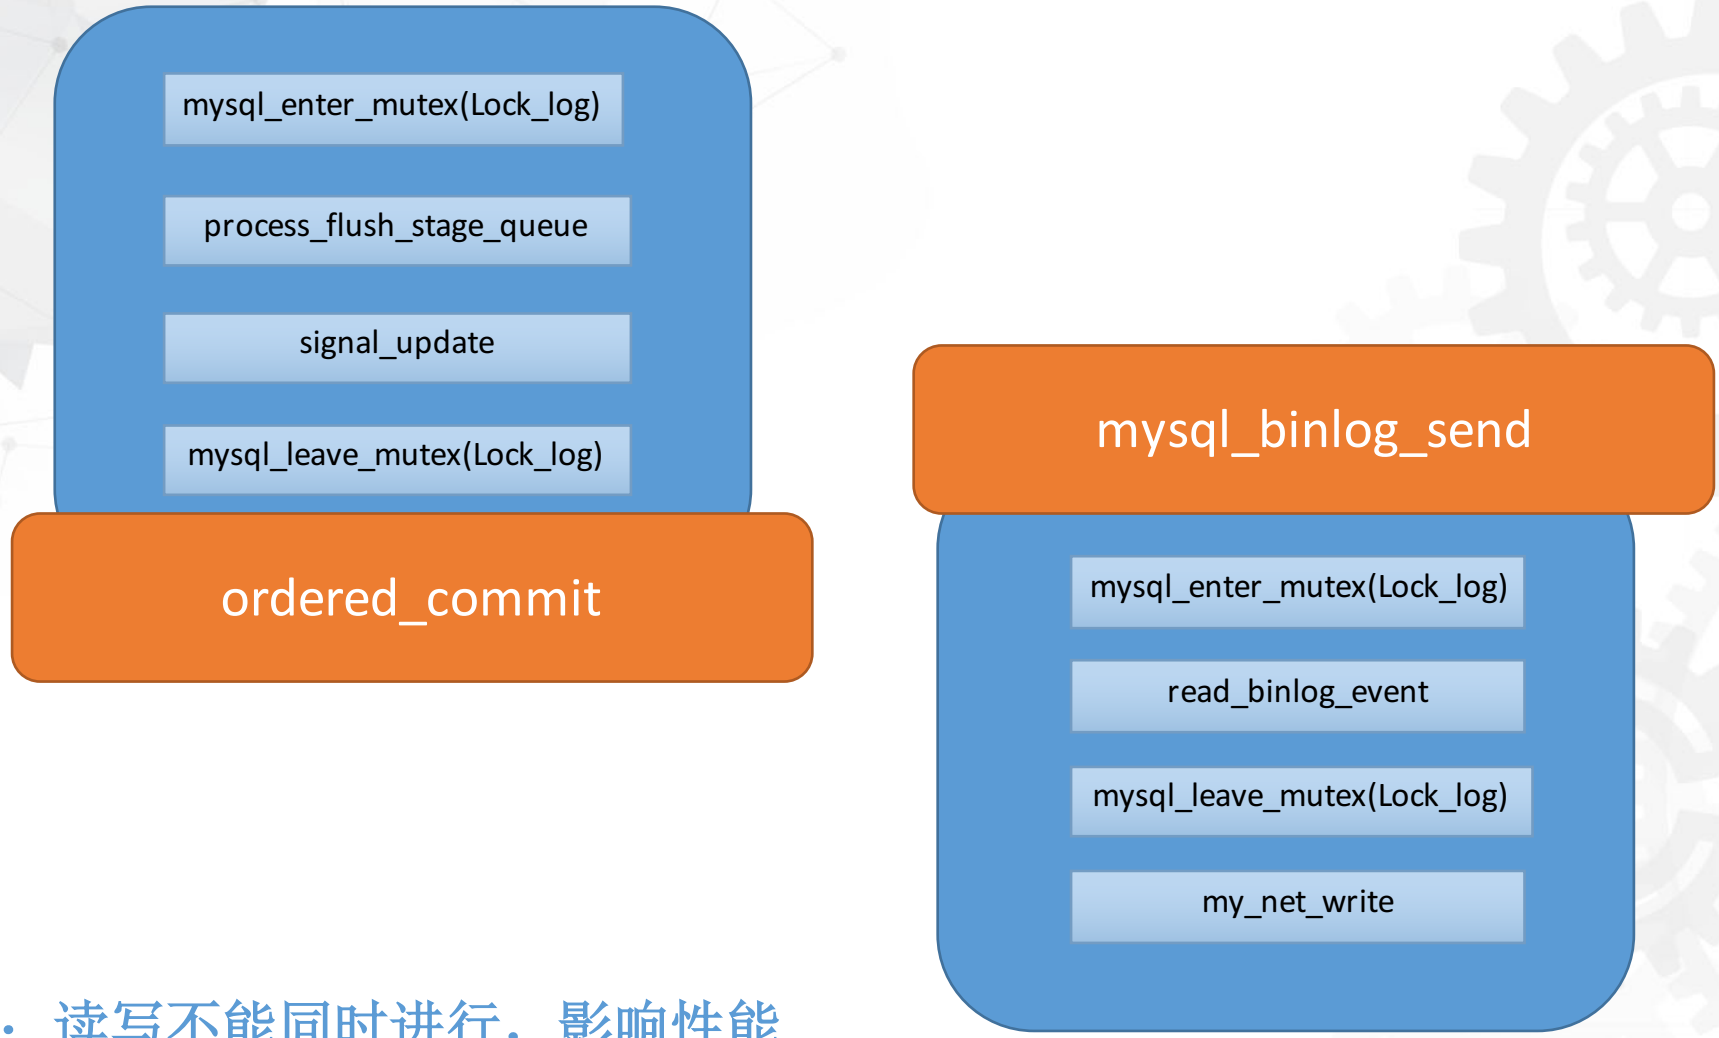

问题：读写不能同时进行，影响性能

主库 Lock_log 锁拆分(Cont.1)

binlog 写线程 & binlog_sender 线程中的优化方式

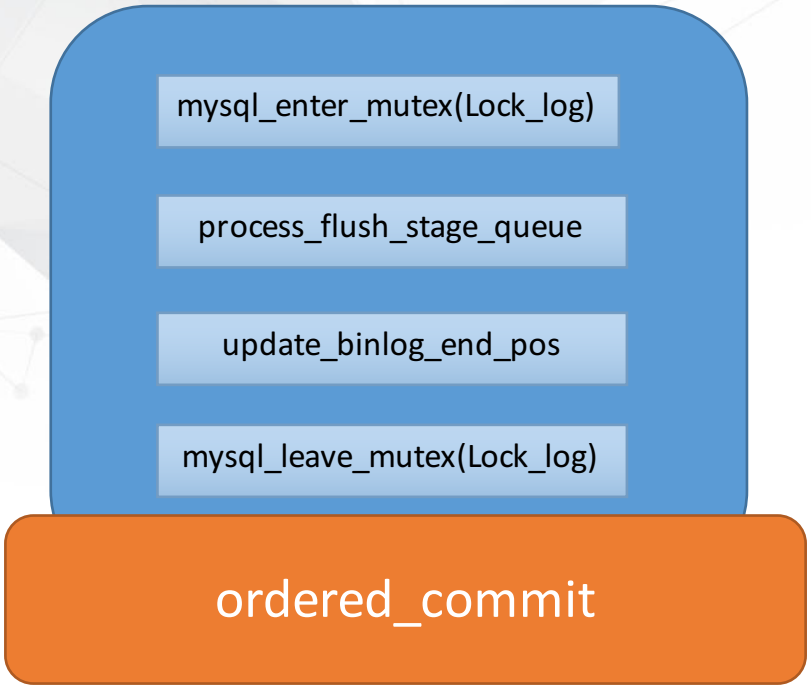

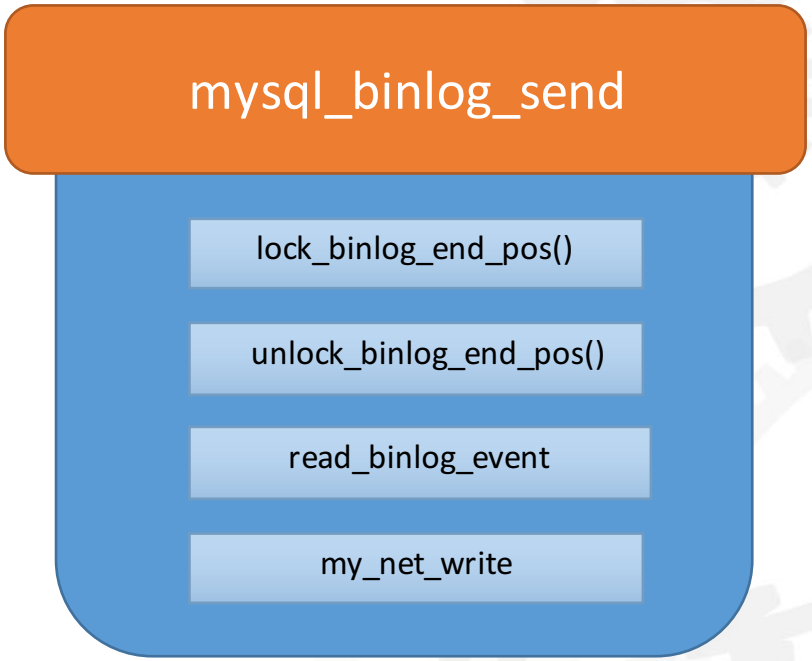

优点：读写同时进行，降低 dump 线程影响

TXSQL 性能数据对比

- ✓ 读性能数据对比
- ✓ 写性能数据对比
- ✓ 读写混合数据对比

读性能数据对比

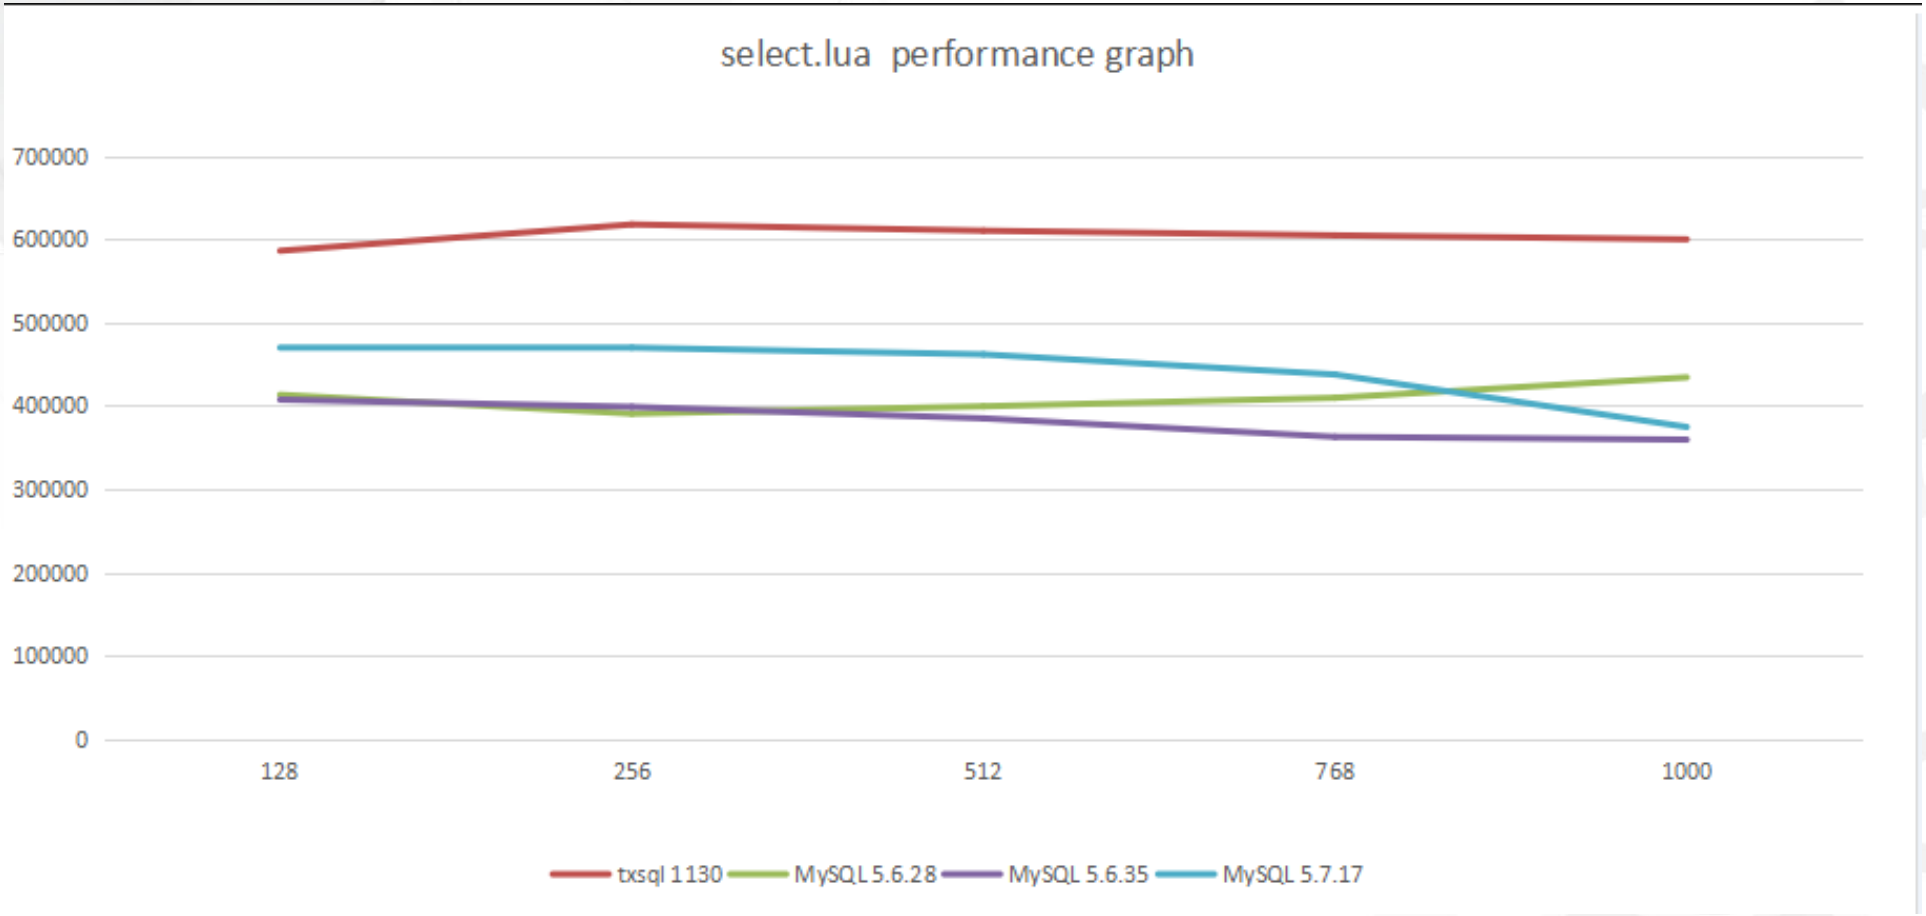
select.lua performance graph
700000
600000
500000
400000
300000
200000
100000
0
128
256
512
768
1000
txsql 1130
MySQL 5.6.28
MySQL 5.6.35
MySQL 5.7.17

写性能数据对比

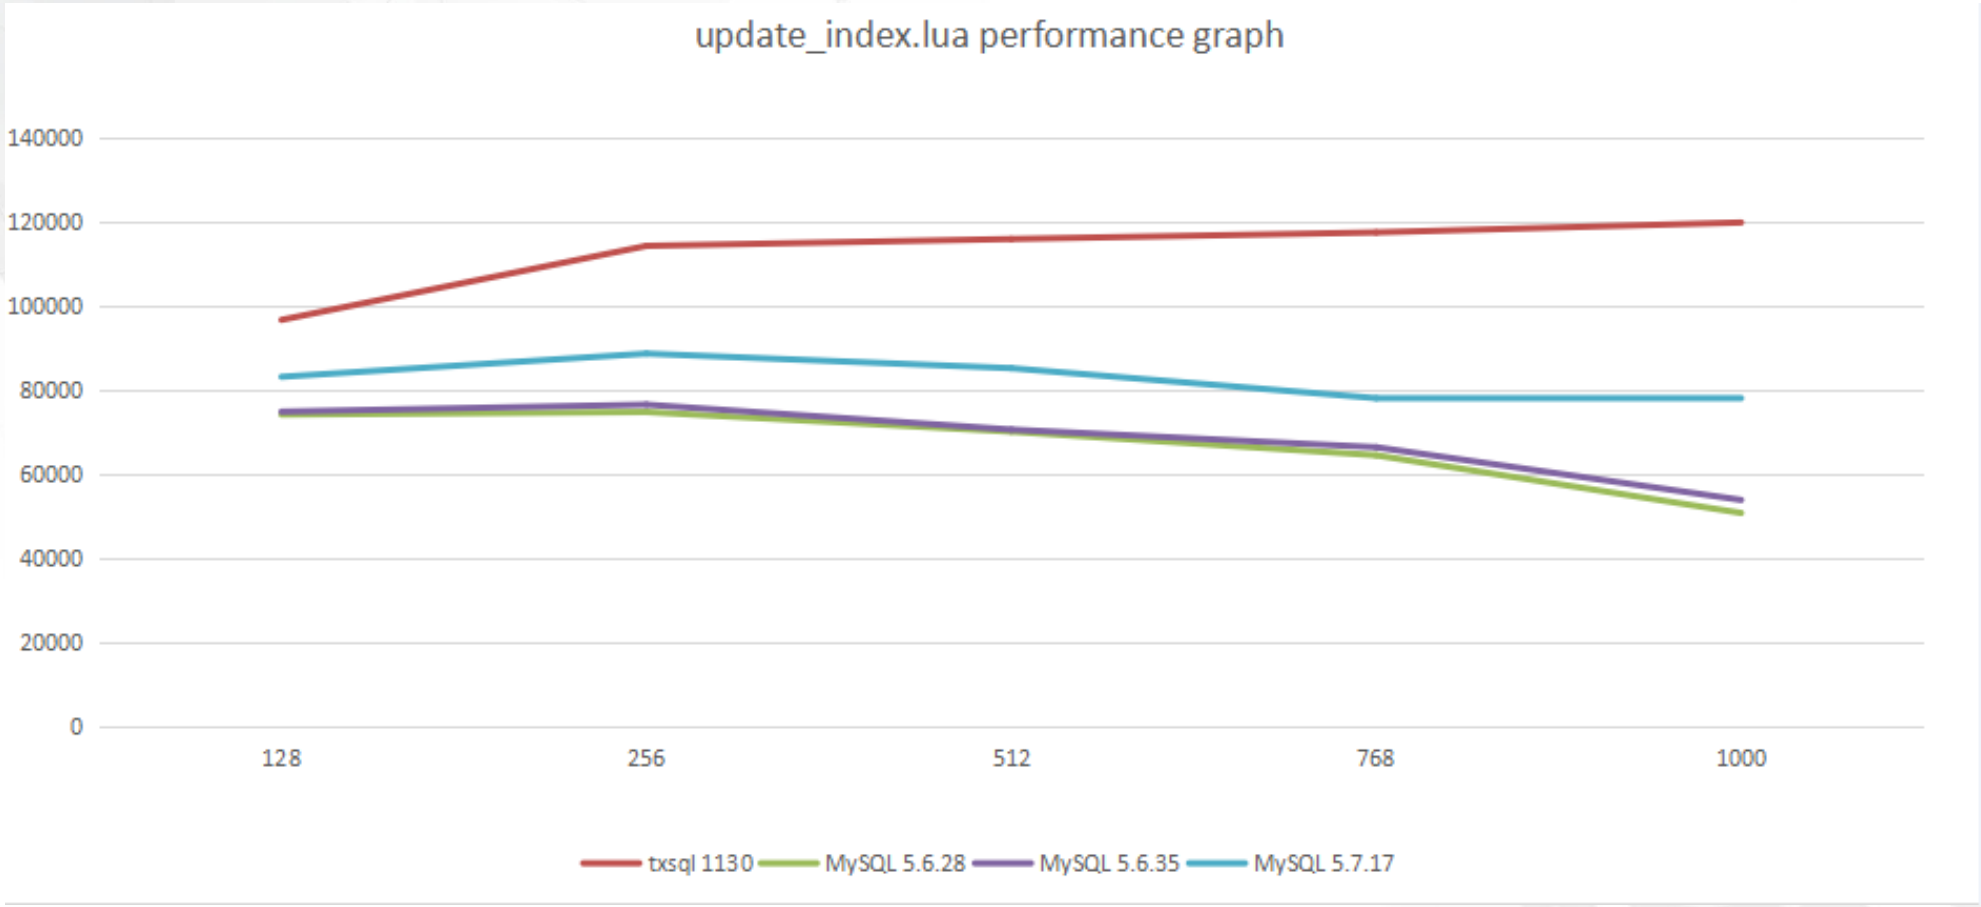
update_index.lua performance graph
140000
120000
100000
80000
60000
40000
20000
0
128
256
512
768
1000
txsql 1130
MySQL 5.6.28
MySQL 5.6.35
MySQL 5.7.17

读写混合数据对比

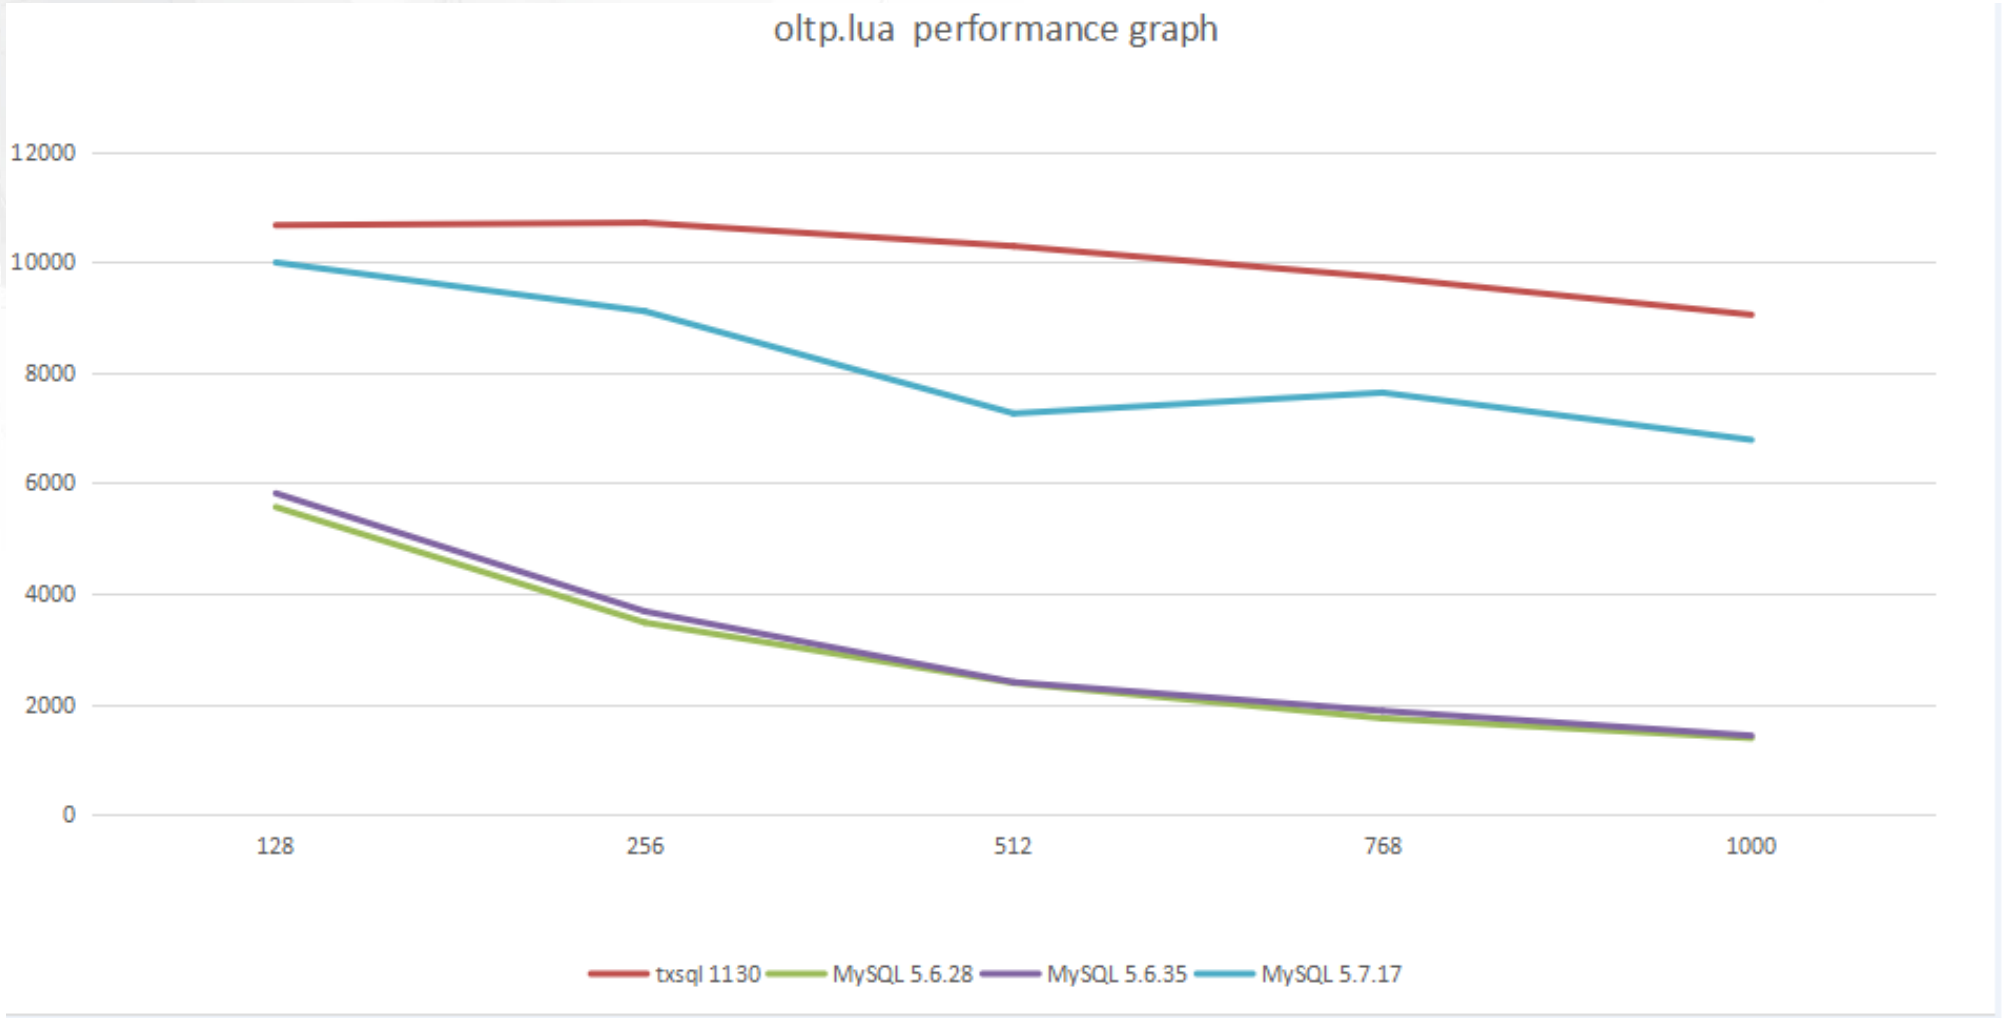
oltp.lua performance graph
12000
10000
8000
6000
4000
2000
0
128
256
512
768
1000
txsql 1130
MySQL 5.6.28
MySQL 5.6.35
MySQL 5.7.17

TXSQL 功能开发

- ✓ TXSQL alter table .. nowait
- ✓ TXSQL 并行复制
- ✓ TXSQL thread pool support

TXSQL alter table .. nowait

DDL 在运维过程中存在的问题

此时，系统相关线程处于waiting 状态，影响业务的后续访问；

TXSQL alter table .. nowait (con1.)

解决问题的方法：

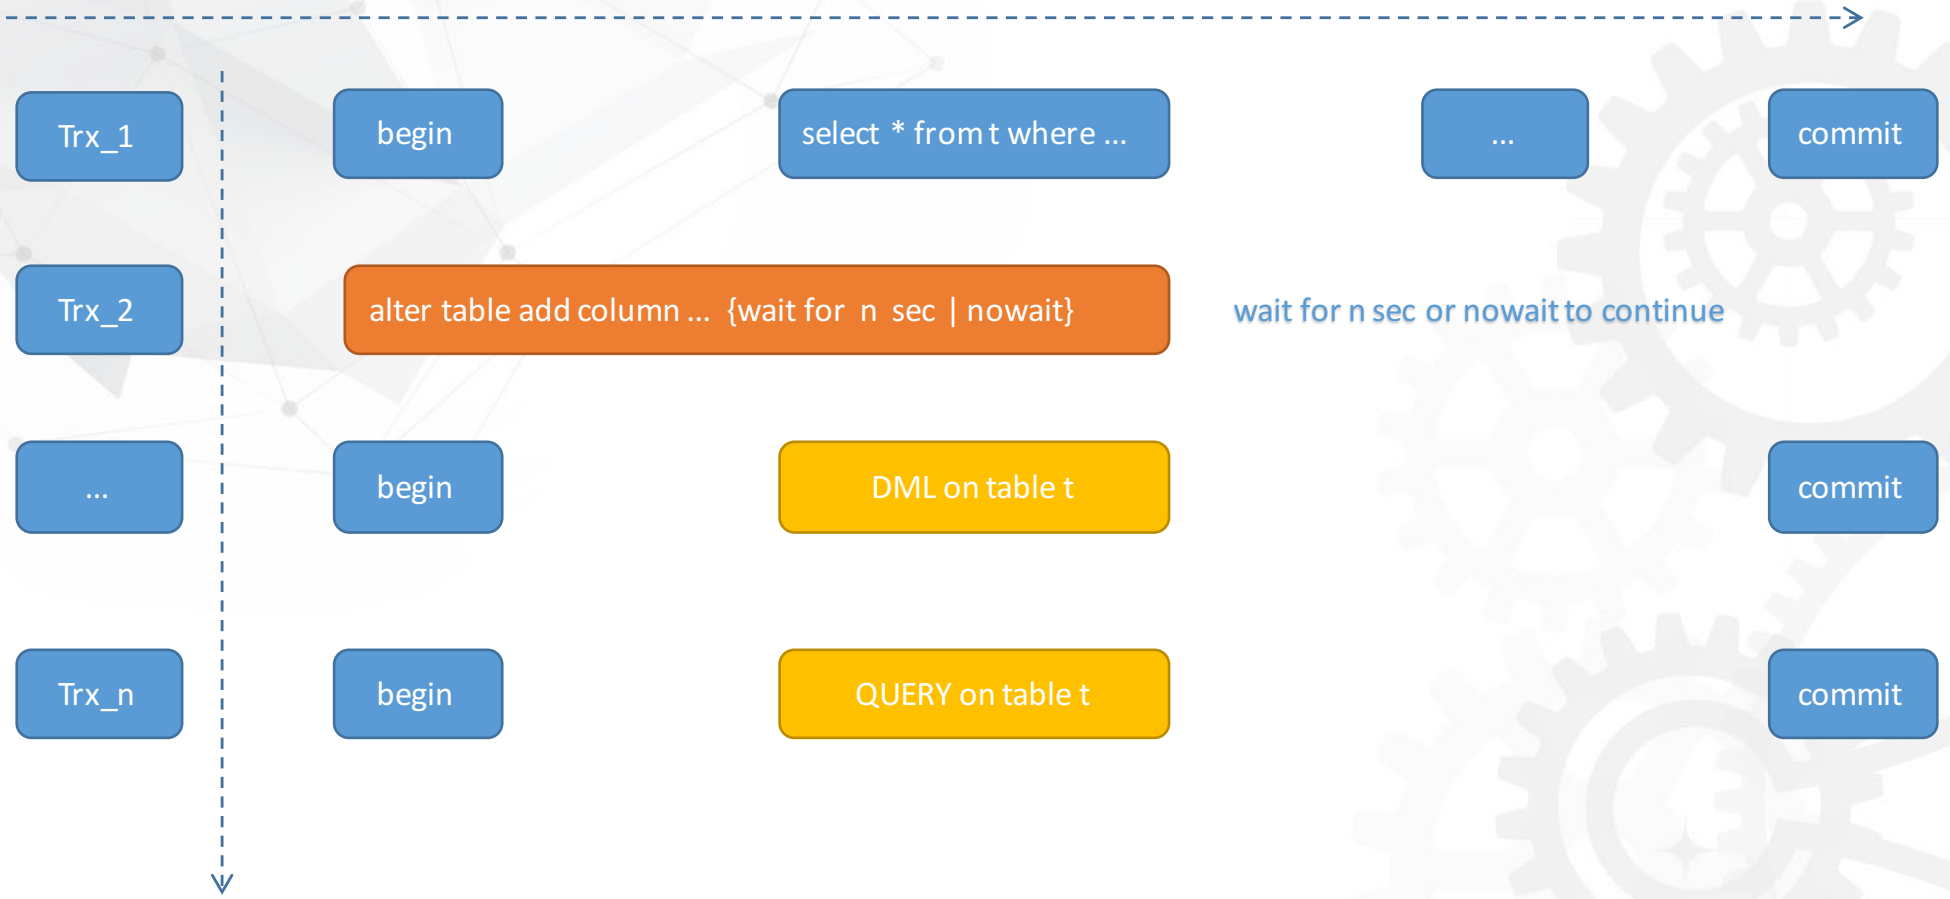

提交新的语法支持以避免上述问题的发生

TXSQL 并行复制

MySQL 复制的原理及发展历程

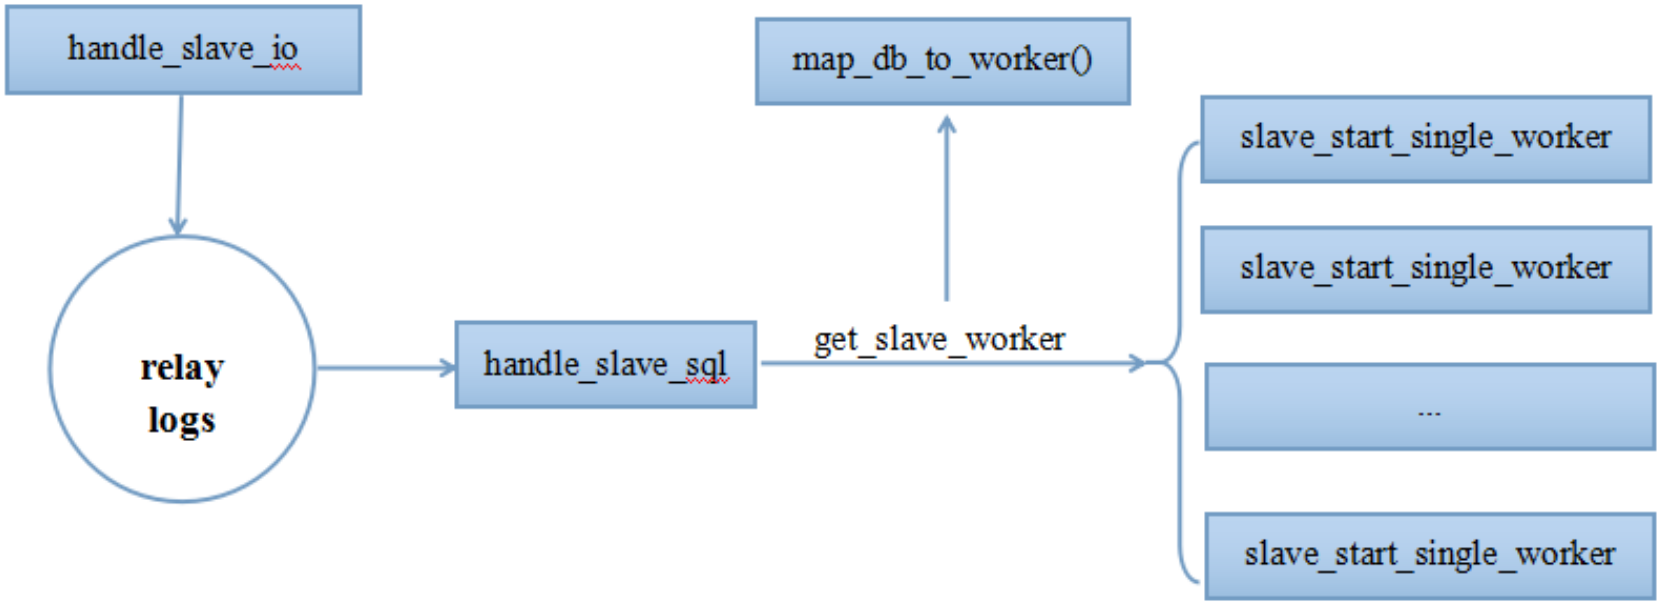

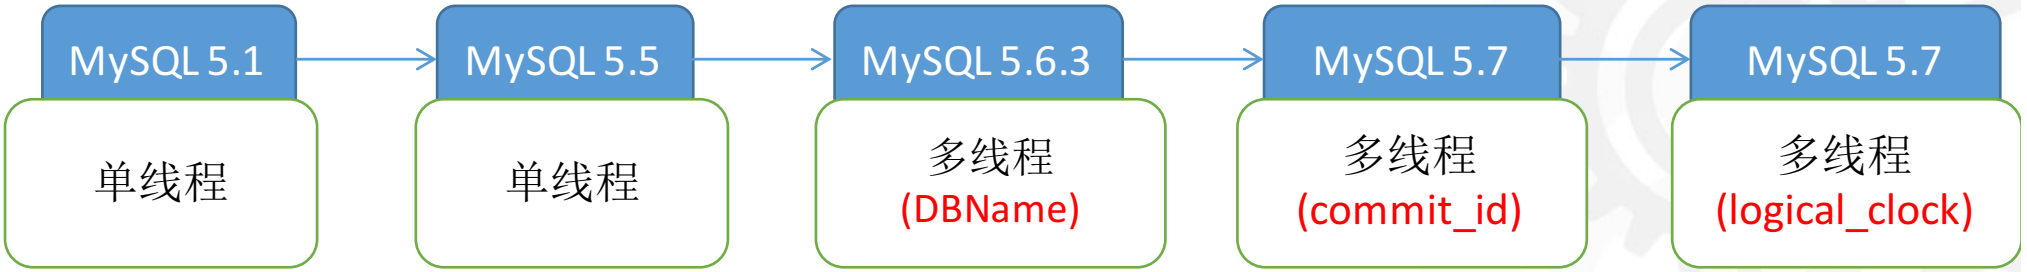

TXSQL 并行复制(Cont.1)

MySQL 并行复制存在的问题

在实际的应用环境中，实例中往往只有一个 Database，导致 relay log 中的事务大部分会分到同一个 worker 线程中，造成备库的性能低下，当主库的性能超过备库的单线程执行的性能时，就会出现延迟，对只读实例产生影响；

TXSQL 并行复制存在的优化

为了解决上述问题，TXSQL 添加了另外一种分发方式，即基于表粒度的分发，为了实现基于表粒度的分发，TXSQL 对于不同的实现，进行了不同的处理:

- ✓ 当binlog_row_format= ROW 时, 调用 get_slave_worker 直接进行分发；
- ✓ 当 binlog_row_format= statement 时，则需要对语句先进行调用 mysql_parse 对语句进行解析，然后再做分发；

TXSQL thread pool 的支持

为什么需要 thread pool 功能

innodb_thread cocurrency 可以控制进行 innodb 工作的线程数，以降低大并发对系统的负载影响，但是原生 MySQL 的Server 层并不能控制 Server 层的线程数，当并发较大、活跃线程较多的时候会有以下问题:

- ✓ MDL lock 锁竞争 & table lock 竞争激烈；
- ✓ Thread running 较高，系统负载较大；
- ✓ Server 层的线程切换较为频繁；
- ✓ Server 层的其它锁资源竞争激烈；

thread pool 的工作原理(Cont.1)

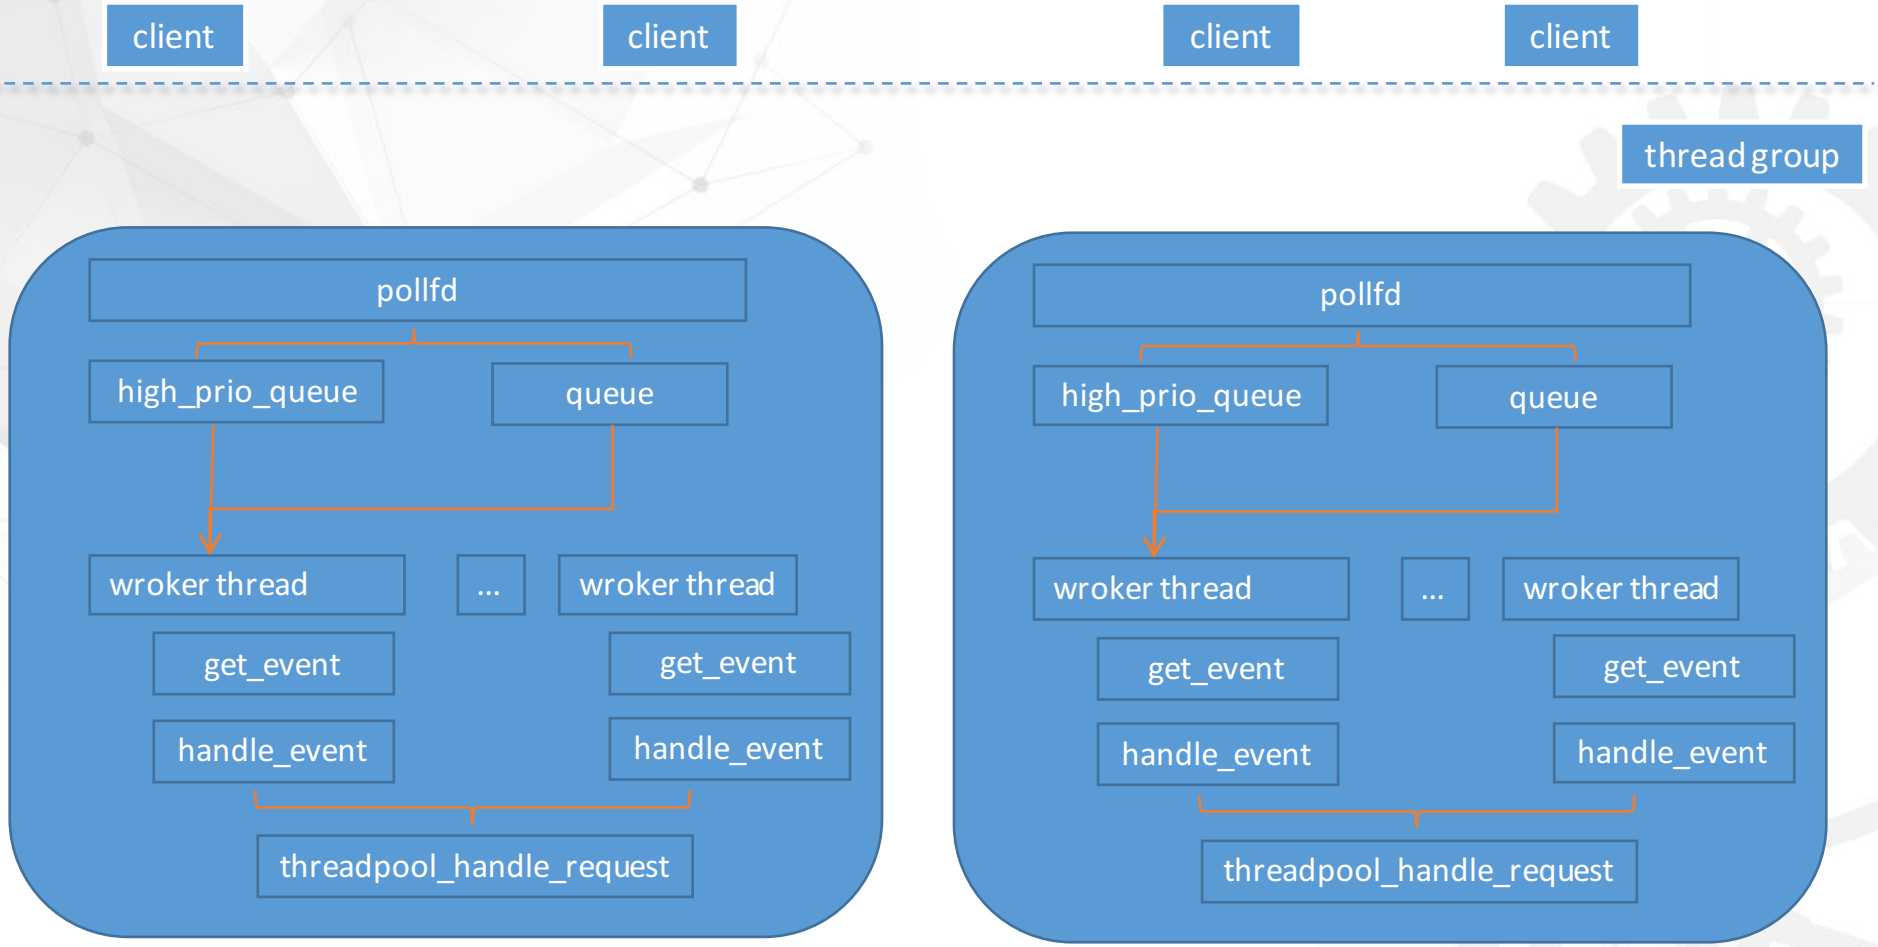

thread_group_size

thread_group_oversubscribe

TXSQL 金融特性

- ✓ TXSQL multi work mode support
- ✓ TXSQL 强同步支持
- ✓ TXSQL 分布式锁支持
- ✓ 其它金融特性相关功能

TXSQL multi work mode support

READ WRITE

实例可以接受读写请求，但系统管理的相关权限被禁用；

READ ONLY

实例只接受读请求，不接受非管理用户的写请求操作；

OFFLINE

MySQL 正常运行但不接受除管理账号以外的其它用户操作；

TXSQL 强同步支持

原生 semi-sync 存在着以下问题：

- ✓ semi-sync 在时间超过 rpl_semi_sync_master_timeout 会退化为异步;
- ✓ 采用 select 进行监听，当句柄值大于 1024 时则会出现异常，详情可参考 bug#79865;
- ✓ 在 after commit 后等待 ACK 容易出现幻读的问题;

TXSQL 强同步支持：

- ✓ 优化半同步，增加ack线程，收发并行化;
- ✓ 修正select时fd超过1024导致异常的bug，改为poll;
- ✓ 在半同步基础上实现强同步，一直hold住直到收到ack;
- ✓ 修改同步方式时，唤醒正在等待的用户线程，继续等待或者退出;
- ✓ 增加一些状态，用于展示当前等待的情况(正在等待的binlog位点，已等待时间);
- ✓ 对于主多 binlog 备少 binlog 的情况进行特殊的处理，以保证双写的情况不会发生;

TXSQL 分布式锁支持

MySQL 锁系统有两个特征：

- ✓ MYSQL 中的锁与连接强依赖，在连接断开之后便会释放其占有的锁资源，包括 server 层 & engine 层的所有锁资源；
- ✓ 用户线程获取锁之后，如果没有显示释放锁资源，连接没有断开亦或事物没有提交，则会一直占有锁资源；

TXSQL 分布式锁

TXSQL 对 MySQL的锁系统进行了扩展，实现了一种跨事务的、与连接无关的租约读写锁，用于应用层实现分布式事务；

cdb_lock() ：多用户对同一个锁对象key加锁，会在加锁超时前等待。直到获取到锁或者超时返回；

cdb_unlock(): 主动锁释放。会对指定锁key的持有者释放锁，只有在锁持有情况下才会成功；

TXSQL 云上优化实践

- ✓ XX 游戏数据库优化案例
- ✓ XX 优化案例

XX 游戏数据库优化案例

问题现象

- ✓ 性能不能满足业务要求，游戏业务逻辑 TPS 不达标；
- ✓ 在压力达到一定程度时，CPU 不能充分利用，idle 较高；
- ✓ 性能抖动较为明显；
- ✓ thread running 过高，系统负载较高；
- ✓ 系统 IO 压力较小，IO 没有问题；

问题排查

pt-pmp & pstack & mysql 命令进行问题排查，发现以下问题：

1. 应用在执行SQL语句的过程中，table_cache_manager 中的锁冲突比较严重；
2. MySQL Server 层中的 MDL_lock 冲突比较重；
3. 实例开启了 Performance_schema 功能；
4. 事务锁 trx_sys->mutx 冲突较高；

XX 游戏数据库优化案例(Cont.1)

调优过程

根据已经查找出来的问题，调整相应参数与版本并重启，效果如下图所示：

1. table_open_cache_instances= 32
2. metadata_locks_hash_instances= 32
3. performance_schema= OFF
4. 其它

dtime	load_1	idlecpu	com_insert	com_update	com_delete	com_select	com_tps	threads_running	threads_conns
2016-07-03 22:21:31	1.54	37.00	1995	8194	0	125782	10189	18	1012
2016-07-03 22:21:32	1.54	37.00	2205	8016	0	125974	10221	17	1012
2016-07-03 22:21:33	1.54	49.00	2061	5758	0	106469	7819	25	1012
2016-07-03 22:21:34	1.54	38.00	2450	7565	0	127511	10015	18	1012
2016-07-03 22:21:35	3.66	39.00	2121	6644	0	128277	8765	27	1012
2016-07-03 22:21:36	3.66	41.00	2617	5966	0	127987	8583	22	1012
2016-07-03 22:21:37	3.66	43.00	2009	6564	0	124135	8573	16	1012
2016-07-03 22:21:38	3.66	43.00	2294	5783	0	123519	8077	15	1012
2016-07-03 22:21:39	4.65	45.00	2050	6931	0	123719	8981	13	1012
2016-07-03 22:21:40	4.65	51.00	2039	5028	0	107993	7067	14	1012
2016-07-03 22:21:41	4.65	49.00	2041	5153	0	110077	7194	23	1012
2016-07-03 22:21:42	4.65	49.00	2215	5347	0	108539	7562	24	1012
2016-07-03 22:21:43	4.65	40.00	2000	7564	0	128957	9564	21	1012

XX 优化案例

问题背景

- ✓ 在压力达到一定程度时，CPU 不能充分利用，idle 较高；
- ✓ 性能抖动较为明显；
- ✓ thread running 过高，系统负载较高；
- ✓ IO 无压力
- ✓ 网络成为系统瓶颈

问题排查及解决过程

- ✓ 使用 pt-pmp 获取压测时 mysqld 的运行时信息，发现 lock_private 时的锁冲突较大；
- ✓ 使用 perf record -g -a -p {pidof mysqld} -F99 -- sleep {t} 进行采集，使用 perf report --stdio 进行统计，查找使用 cpu 较多的地方，然后调整相关参数；
- ✓ 查看网卡与 CPU 的绑定情况，然后进行相应的调整，解决网络拥堵的问题；
- ✓ 替换最新版本，引入 redo log 的写优化，提升整体的吞吐量；

数据库问题总结

- ✓ 在压力达到一定程度时，CPU 不能充分利用，idle 较高；
- ✓ 性能抖动明显；
- ✓ 并发过大引起的 thread running 过高，系统负载较高；
- ✓ IO 问题引起的性能抖动；
- ✓ 锁问题导致的性能抖动；
- ✓ 压力不够大或者压力不均匀；
- ✓ 优化器问题引起的执行计划出错；
- ✓ SQL 语句引起的异常；
- ✓ 参数配置的不合理；
- ✓ 内核 Bug；
- ✓ 网络问题；

TXSQL 未来发展方向

- ✓ 批量计算
- ✓ 执行计划缓存
- ✓ XA 三阶段支持
- ✓ 基于 binlog 的深度优化
- ✓ Innodb 的持续优化
- ✓ 引入 oracle 企业级特性

Welcome to join us!


THANKS
SequeMedia
盛拓传媒
ITPUB
ChinaUnix