

## 100亿数据量+10万并发量+1万属性+复杂查询数据架构设计

58到家-沈剑

SequeMedia







#### 关于-我

- 前百度 高级工程师
- 58同城 高级架构师, 技术委员会主席, 技术学院优秀讲师
- 58到家 高级技术总监, 技术委员会主席
- "架构师之路"作者,深夜写写技术文章
- 本质:技术人一枚



#### 目录

- 需求缘起
- 初级解决方案
- 优化解决方案
- 总结

## (1)需求缘起

#### 诉求

- 100亿的数据量
- 10万的并发
- 1万属性
- 任意字段都可能进行组合查询

### 什么业务这么变态?

#### 58最核心的业务-帖子业务

• 10年累计帖子量: 10亿

• 读写并发吞吐量:10万

• 异构帖子属性:1万

• 品类的组合搜索需求

58同城是一个**信息平台**,有很多垂直品类:招聘、 房产、二手物品、二手车、黄页等等,每个品类又有 很多子品类,不管哪个品类,最核心的数据都是"帖 子信息"

#### 帖子信息有什么特点?

- (1) **帖子量很大**,100亿级别
- (2) 查询量很大,每秒几10万级别
- (3)每个品类的**属性干差万别**,招聘帖子和二手帖 子属性完全不同,二手手机和二手家电的属性又完全 不同,目前恐怕有近万个属性
- (4)每个属性上都有查询需求,**各组合属性上都可能有组合查询需求**

#### 业务需求 决定 技术方案

#### (2)潜在解决方案

#### 初版设计-扩充列

开始,一个招聘品类,帖子表:

tiezi(tid,uid, c1, c2, c3)

通过组合索引满足组合查询需求:

index\_1(c1,c2) index\_2(c2, c3) index\_3(c1, c3)

业务发展,新增一个房产类别,新增若干属性,帖子

表升级为:

tiezi(tid,uid, c1, c2, c3, c10, c11, c12, c13)

其中:

c1,c2,c3是招聘类别属性

c10,c11,c12,c13是房产类别属性

新建组合索引满足新的查询需求?

- (1)不敢想有多少个索引才能覆盖所有两属性查询
- (2)三属性查询,根本玩不下去?

#### 另一种设计-扩充表

#### 按照业务做垂直拆分

tiezi\_zhaopin(tid,uid, c1, c2, c3) tiezi\_fangchan(tid,uid, c10, c11, c12, c13) 每个业务有**帖子服务,搜索服务**,分别满足垂直的数据库查询,帖子检索需求

#### 维护在不同的部门的数据库、服务、搜索,**看上去各业务线灵活性强,这恰恰是悲剧的开始**:

- (1)按照uid来查询怎么办(查询自己发布的所有帖子)?
- (2)按照时间来查询怎么办(最新发布的帖子)?
- (3)跨品类查询怎么办(例如首页搜索框)?
- (4)技术范围的扩散,有的用mongo存储,有的用mysql存储,有的自研存储
- (5) 重复开发了不少组件
- (6)总体维护成本过高(想想看,电商的商品表,不可能一个类目一个表的)
- (7)...

#### (3)优化解决方案

#### 统一的帖子服务

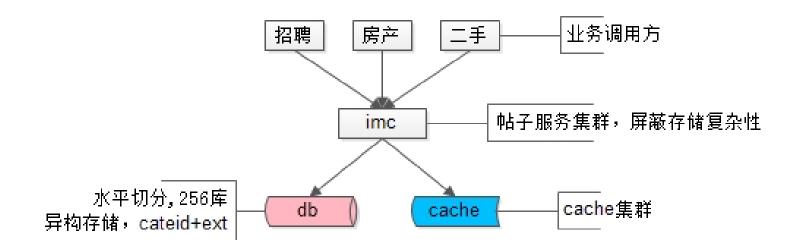
#### 帖子中心-数据库

tid	uid	time	cateid	ext	
1	1	123	招聘	{"job":"driver","salary":8000,"location":"bj"}	
2	1	456	二手	{"type":"iphone","money":3500}	

- (1)一些通用的字段抽取出来单独存储
- (2) 通过cateid来定义ext是何种含义
- (3)通过ext来存储不同业务线的个性化需求

#### 如何解决海量数据问题?

#### 帖子中心-服务



- (1)数据库水平切分,256库
- (2)分层抽象,抽取服务层,屏蔽底层复杂性

#### 新出现的问题?怎么解决?

- (1) key作为字符串,重复存储,占据大量空间
- (2) cateid不足以描述ext内容,层级/深度不确定
- (3)如何随时增加属性,对属性进行规范
- (4) value如何进行约束

### 统一的类目属性服务

#### 类目属性-数据库

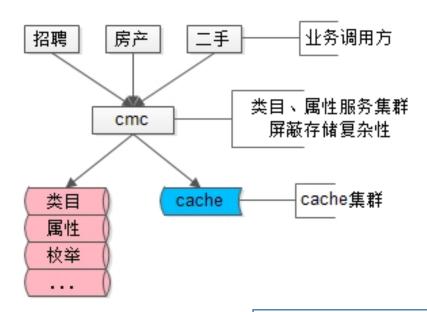
tid	uid	time	cateid	ext	
1	1	123	招聘	{"1":"driver","2":8000,"3":"bj"}	
2	1	456	二手	{"4":"iphone","5":3500}	

key_id	cateid	sub_cateid	desc	show	正则校验	XX
1	招聘	100	job	职位	32字符	
2	招聘	100	salary	薪水	uint类型	
3	招聘	100	location	位置	8字符	
4	二手	200	type	类型	short类型	
5	二手	200	money	价格	uint类型	

key_id	value_enum	show
4	1	三星
4	2	小米
4	3	魅族
4	4	vivo
4	5	iphone

- (1) 帖子中心的key是数字
- (2)类目属性库描述分类、属性含义、值约束
- (3) value不是正则,枚举表限定值域

#### 类目属性-服务

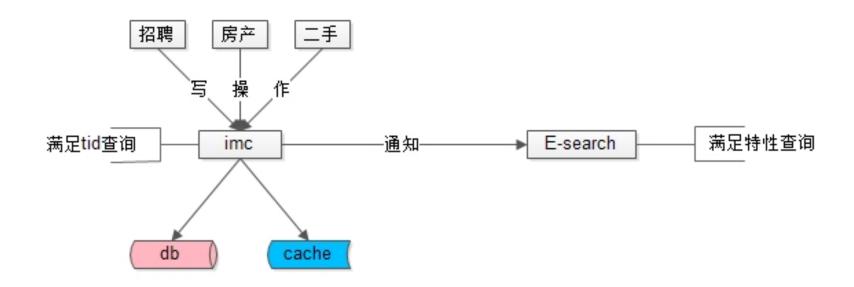


- (1)随时扩展属性,方便约束,减少空间
- (2)分层抽象,抽取服务层,屏蔽底层复杂性
- (3) 类目变化频度低,缓存命中率极高

#### 多属性组合查询的需求怎么办?

#### 外置索引,统一的搜索服务

#### 帖子搜索-服务

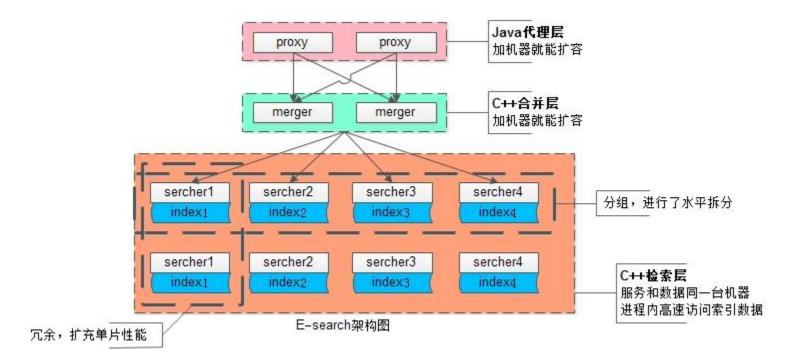


- (1) tid正排查询, 走帖子服务
- (2)复杂搜索查询,走E-search搜索服务
- (3) 帖子变化,通过MQ通知

## 如何满足100亿数据,10万并发的搜索?

水平扩展,加机器就能扩容是正道

#### 搜索服务-扩展性

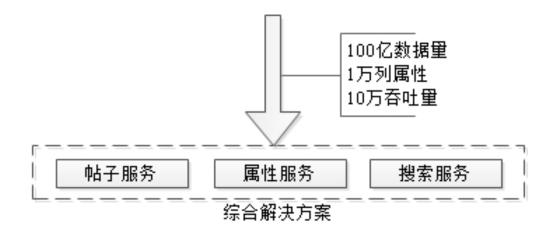


- (1) proxy代理层,无状态,加机器就能扩容
- (2)合并层,无状态,加机器就能扩容
- (3)检索层,服务和索引同机部署,性能高
  - -> 数据水平切分,数据可扩展
  - -> 数据冗余多份,并发可扩展

效果:100亿查询,10ms返回

(4)总结

#### 总结



100亿数据量,10万吞吐量,1万属性,复杂复合查询

->

- (1)元数据服务,**帖子服务** =
- (2)属性扩展服务,属性服务
- (3)外置索引,搜索服务

"架构师之路"公众号



# THANKS

SequeMedia <sup>盛拓传媒</sup>





