DTCC

2017第八届中国数据库技术大会

DATABASE TECHNOLOGY CONFERENCE CHINA 2017

Kudu介绍及实践

小米 张震

大纲

- Kudu介绍
- Kudu与Spark的整合
- 小米实践

存储系统的现状

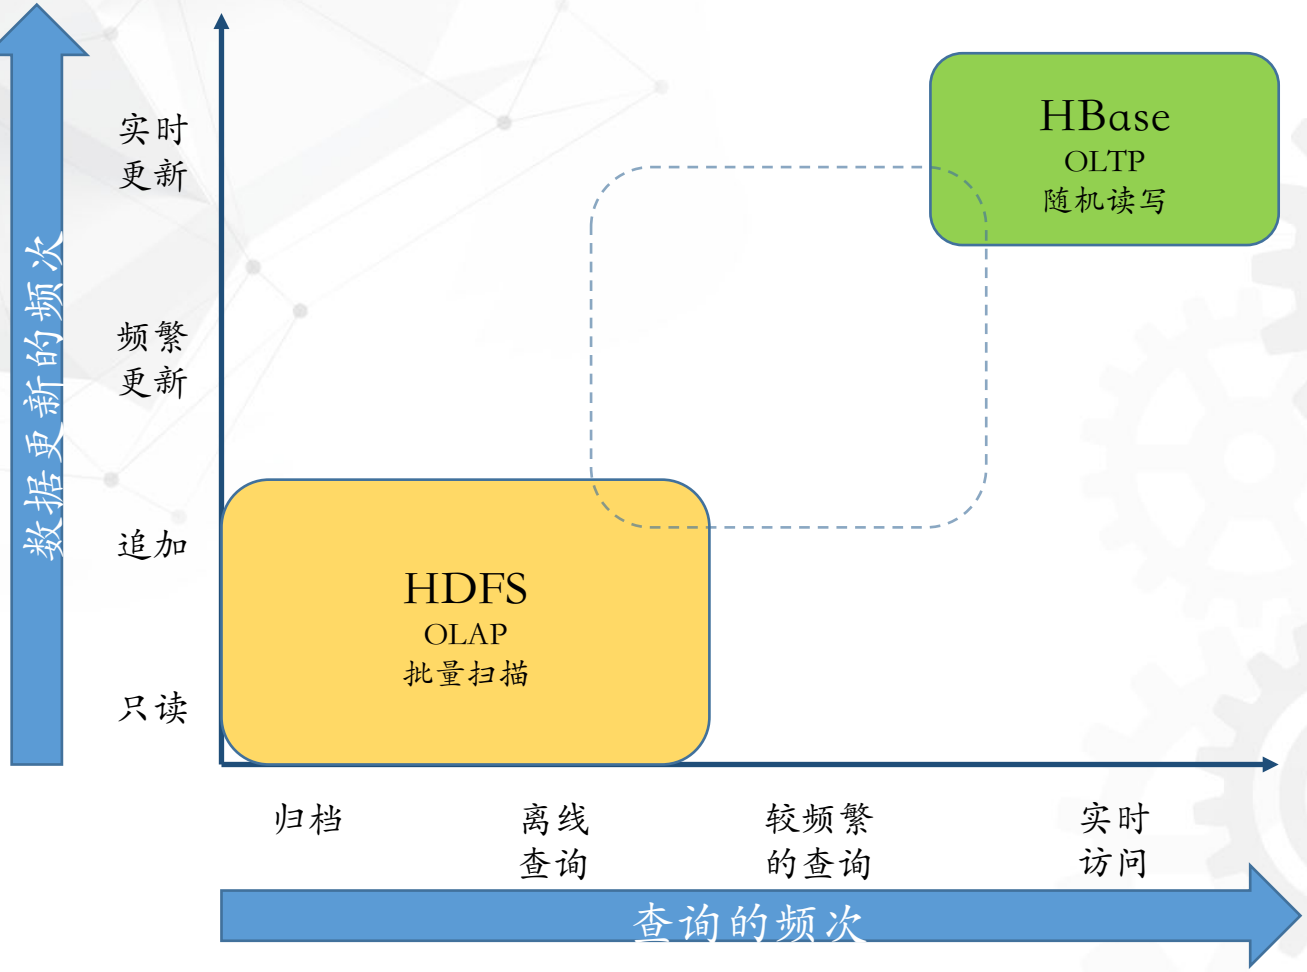
数据更新的频次
实时更新
频繁更新
追加
只读
HBase
OLTP
随机读写
HDFS
OLAP
批量扫描
归档
离线查询
较频繁的查询
实时访问
查询的频次

Kudu的设计目标

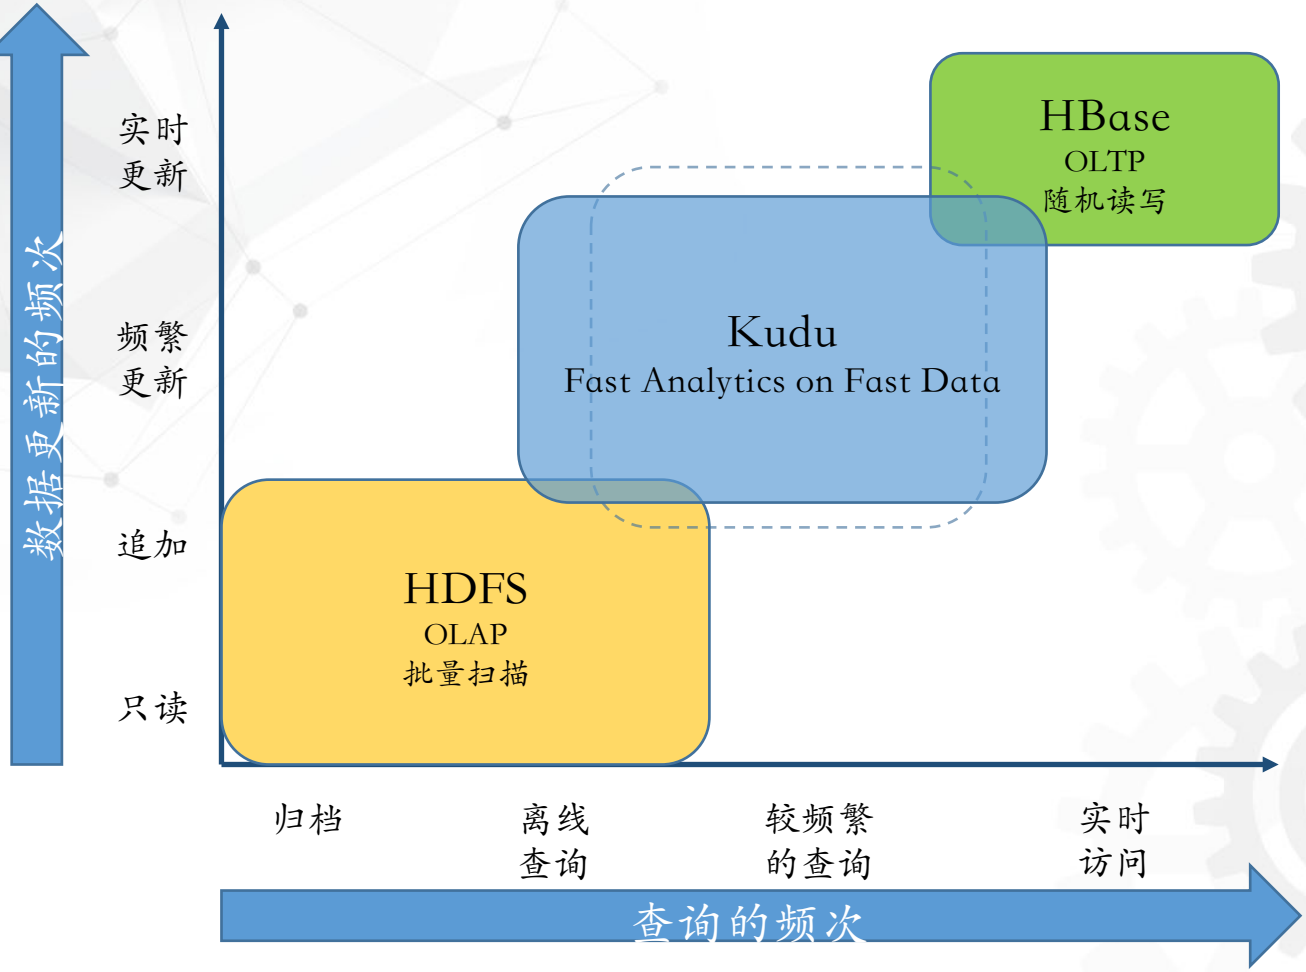
数据更新的频次
实时更新
频繁更新
追加
只读
HBase
OLTP
随机读写
Kudu
Fast Analytics on Fast Data
HDFS
OLAP
批量扫描
归档
离线查询
较频繁的查询
实时访问
查询的频次

Kudu的设计目标

高性能：

- 快速的批量扫描 2x Parquet
- 低延迟的随机读写 1ms on SSD

可扩展：

- 400 nodes，1000s of nodes
- low MTTR

关系型数据模型：

- 强schema，有限列，不支持BLOBs
- NoSQL APIs (insert/update/delete/scan), Java/C++ Client

事务支持：

- 单行的ACID支持

与Hadoop生态的集成：

- Flume/Impala/Spark

Kudu的数据模型

- 有限固定列
- 强类型

```
CREATE TABLE sales_by_year(
   year INT,
   sale_id INT COLPROPERTIES (encoding="bitshuffle"),
   amount INT,
   PRIMARY KEY (year, sale_id)
)
PARTITION BY HASH (sale_id) PARTITIONS 4,
RANGE (year)
(
   PARTITION 2014 <= VALUES <= 2016,
   PARTITION VALUE = 2017
)  STORED AS KUDU
TBLPROPERTIES (replication=3);
```

- 列存储
- 每一列均可以设置encoding及压缩方式
- 主键索引
- 范围分区和哈希分区
- 多副本

分区和Tablet

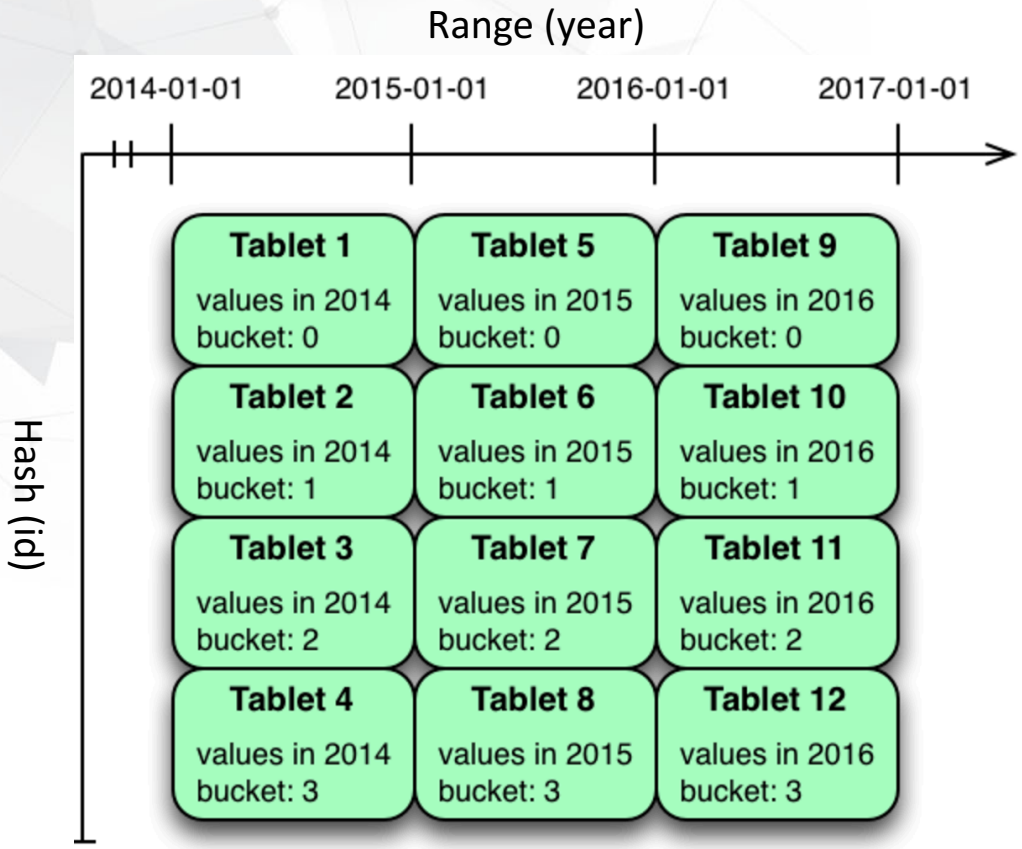


```
PARTITION BY
HASH (id) PARTITIONS 4,
RANGE (year)
(
   PARTITION VALUE = 2014
   PARTITION VALUE = 2015
   PARTITION VALUE = 2016
)
```

多备份

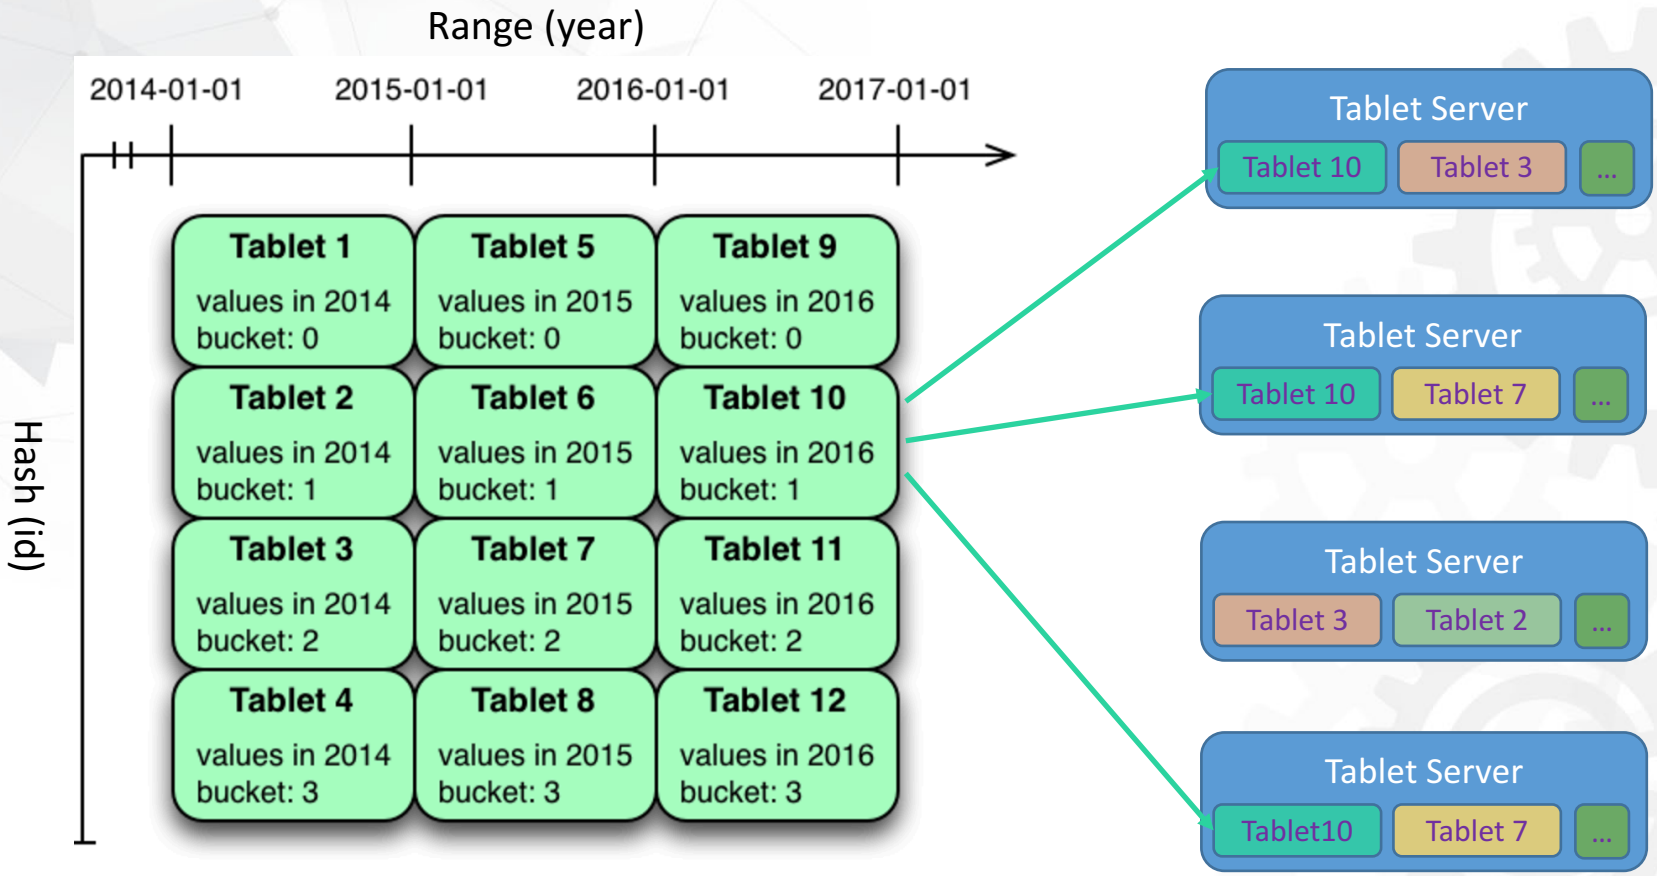
Range (year)
2014-01-01
2015-01-01
2016-01-01
2017-01-01
Hash (id)
Tablet 1
values in 2014
bucket: 0
Tablet 5
values in 2015
bucket: 0
Tablet 9
values in 2016
bucket: 0
Tablet 2
values in 2014
bucket: 1
Tablet 6
values in 2015
bucket: 1
Tablet 10
values in 2016
bucket: 1
Tablet 3
values in 2014
bucket: 2
Tablet 7
values in 2015
bucket: 2
Tablet 11
values in 2016
bucket: 2
Tablet 4
values in 2014
bucket: 3
Tablet 8
values in 2015
bucket: 3
Tablet 12
values in 2016
bucket: 3
Tablet Server
Tablet 10
Tablet 3
...
Tablet Server
Tablet 10
Tablet 7
...
Tablet Server
Tablet 3
Tablet 2
...
Tablet Server
Tablet10
Tablet 7
...

多备份 & raft协议

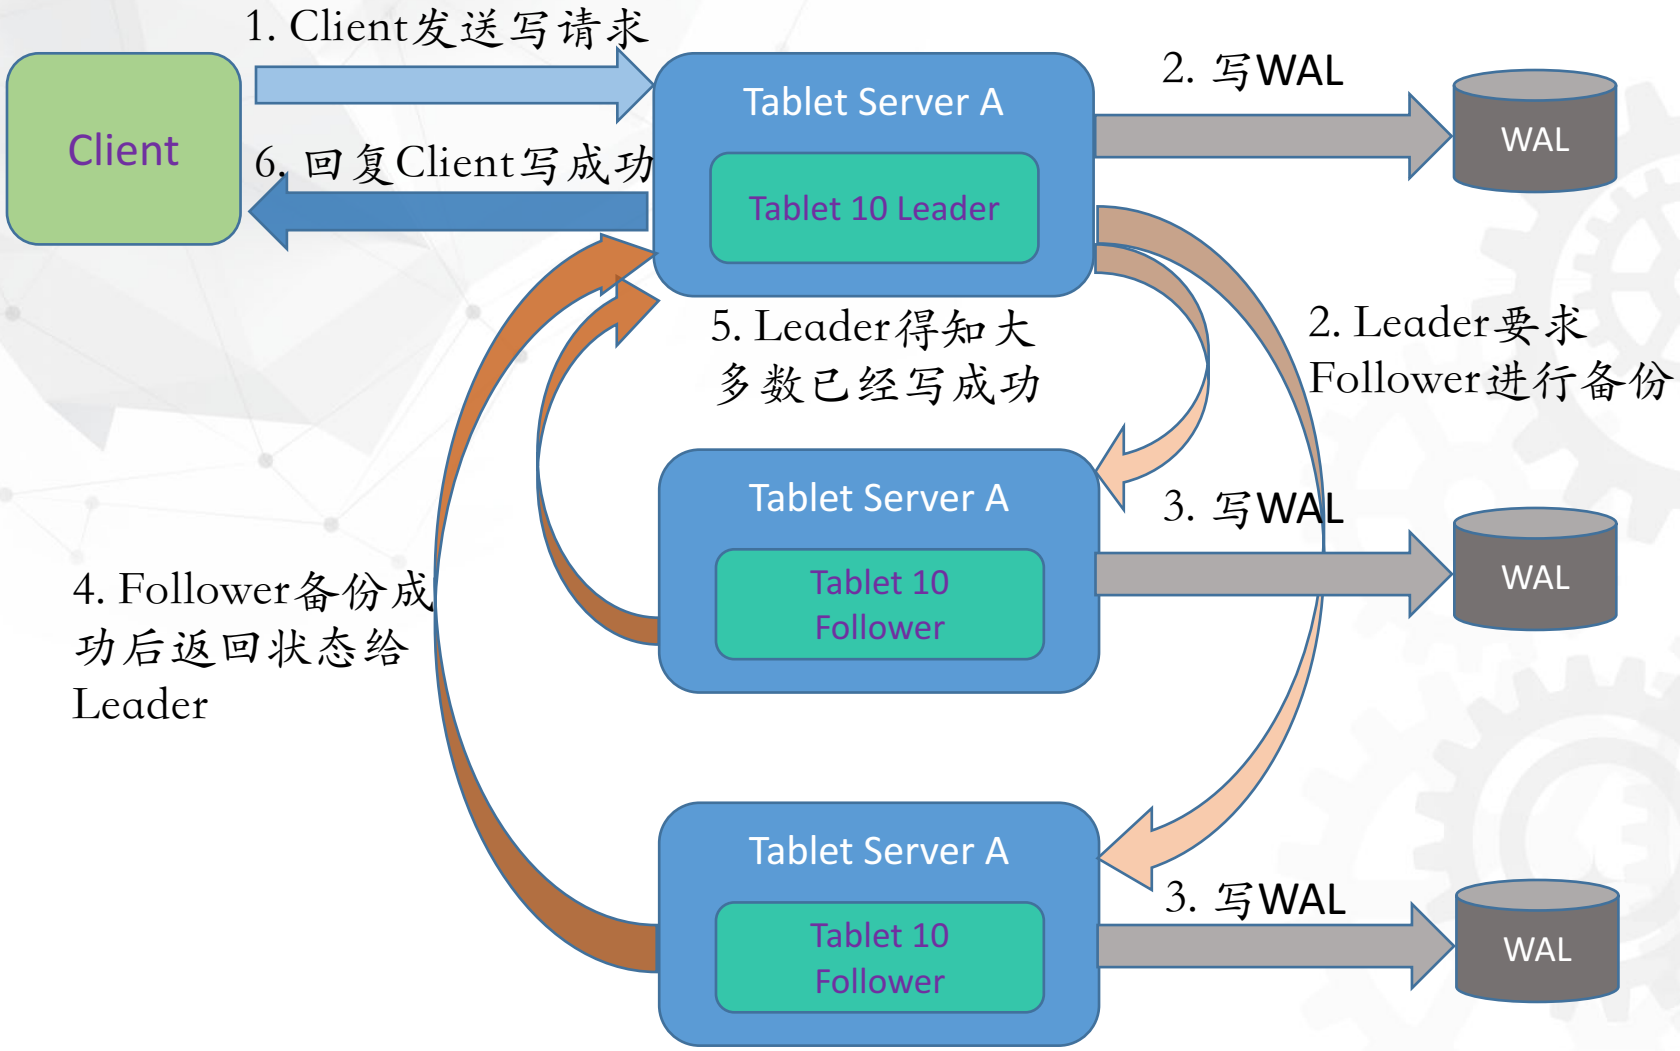
1. Client发送写请求
Client
6. 回复Client写成功
Tablet Server A
Tablet 10 Leader
2. 写WAL
WAL
5. Leader得知大多数已经写成功
2. Leader要求Follower进行备份
Tablet Server A
Tablet 10 Follower
3. 写WAL
WAL
4. Follower备份成功后返回状态给Leader
Tablet Server A
Tablet 10 Follower
3. 写WAL
WAL

多备份 & 容错

多备份：

- 强一致，低延迟
- 允许从Follower进行Snapshot读

临时失败（5分钟内）：

- Leader临时失败 - 自动选主，大概在5s内完成
- Follower临时失败 - 少数的Follower失败不会影响读写

永久失败（超过5分钟）：

- 踢出Raft Config，Master会重新选择一台TabletServer部署新的Replica

整体架构

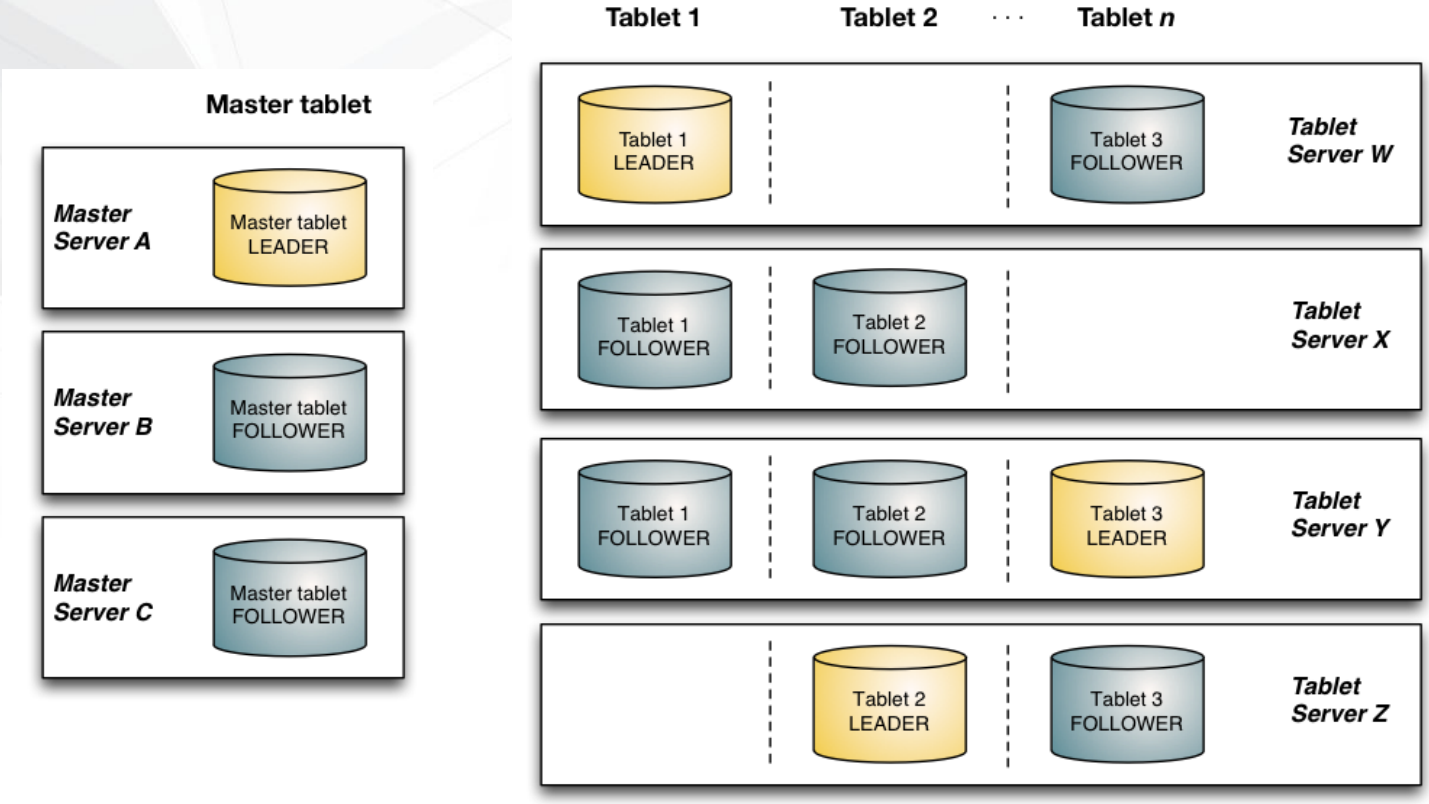
Master tablet
Master Server A
Master tablet LEADER
Master Server B
Master tablet FOLLOWER
Master Server C
Master tablet FOLLOWER
Tablet 1
Tablet 2
· · ·
Tablet n
Tablet 1 LEADER
Tablet 3 FOLLOWER
Tablet Server W
Tablet 1 FOLLOWER
Tablet 2 FOLLOWER
Tablet Server X
Tablet 1 FOLLOWER
Tablet 2 FOLLOWER
Tablet 3 LEADER
Tablet Server Y
Tablet 2 LEADER
Tablet 3 FOLLOWER
Tablet Server Z

Master

特殊的元表：

- 表结构为： type int8, id int64, meta string
  - type为table或tablet
  - id为table id或tablet id
  - meta为protobuf序列化后的元数据
- table元数据
  - schema，partition schema，包含哪些tablets
- tablet元数据
  - replica locations
  - tablet state

Coordinator：

- 接收TabletServer的心跳，跟踪集群状态
- create/alter/drop table
- 对under-replicated的tablet重新分配replica

Master

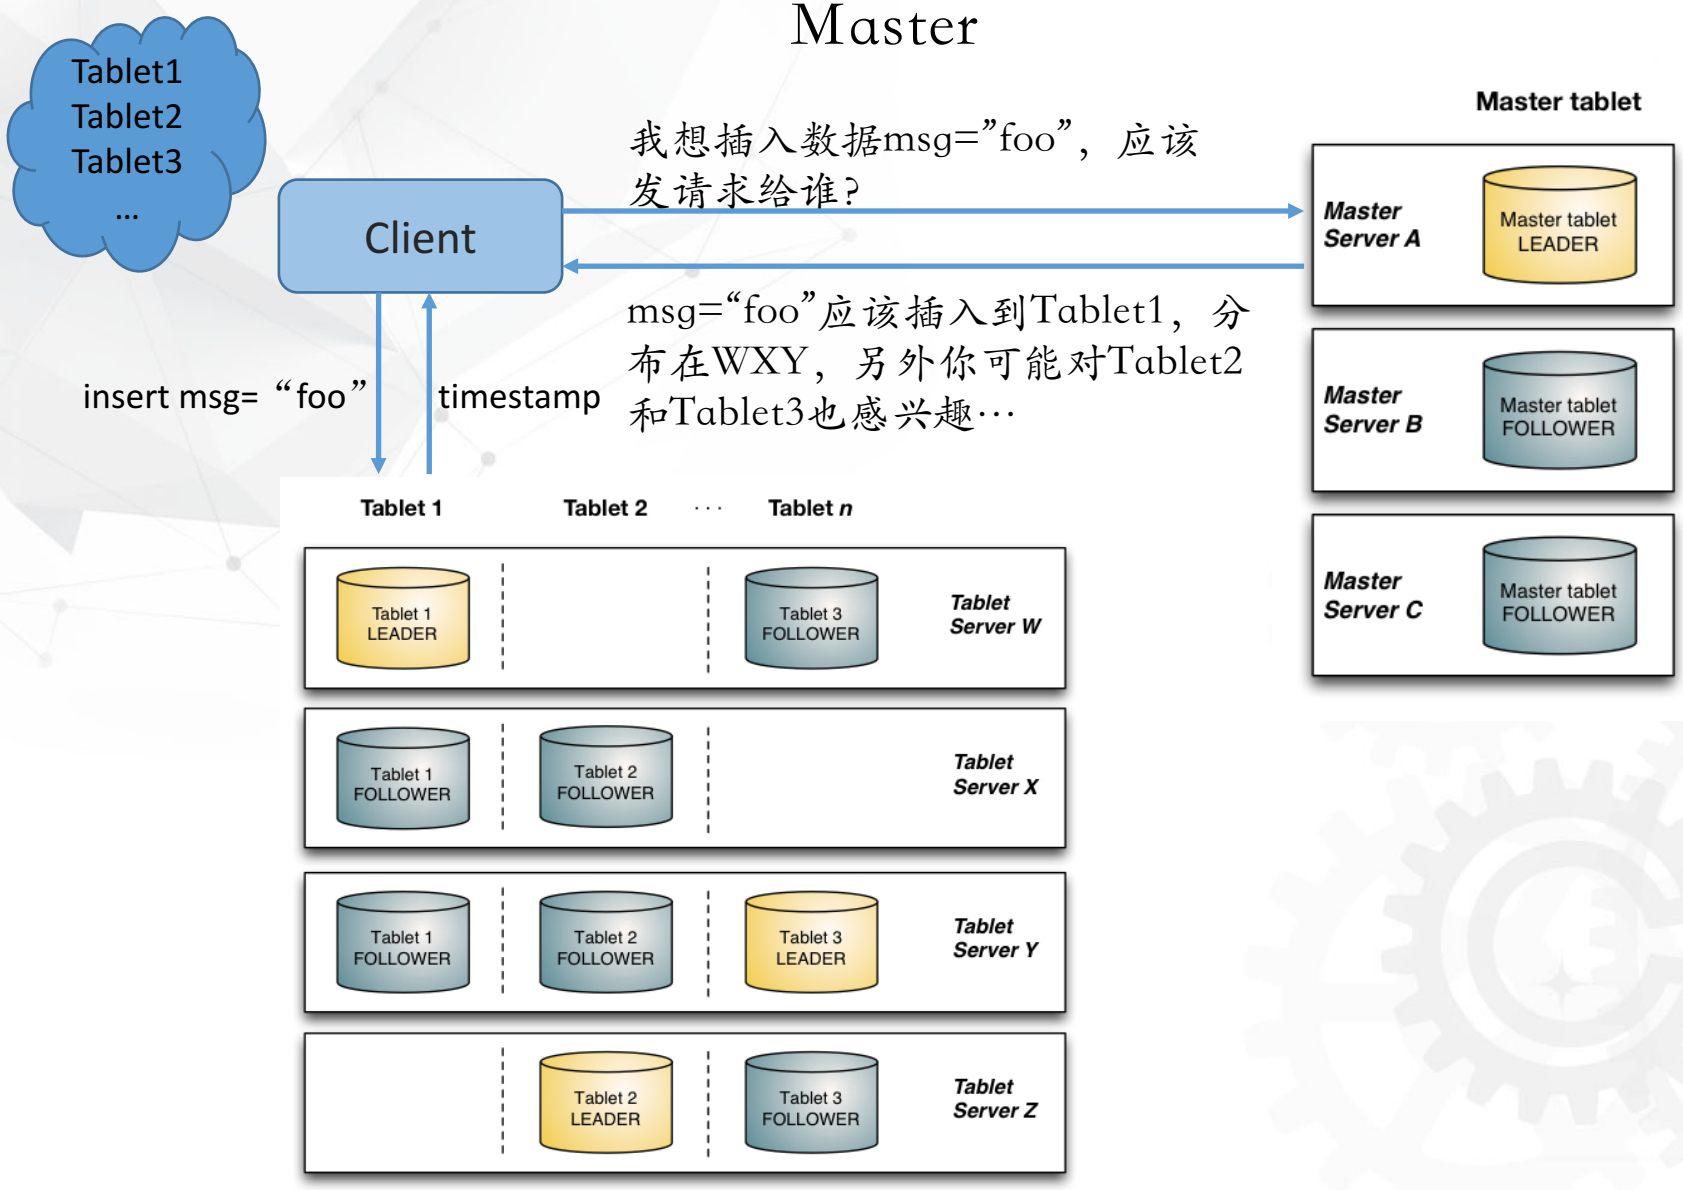
Tablet1
Tablet2
Tablet3
...
Client
insert msg=“foo”
timestamp
我想插入数据msg=”foo”，应该发请求给谁？
msg=“foo”应该插入到Tablet1，分布在WXY，另外你可能对Tablet2和Tablet3也感兴趣…
Master tablet
Master Server A
Master tablet LEADER
Master Server B
Master tablet FOLLOWER
Master Server C
Master tablet FOLLOWER
Tablet 1
Tablet 2
Tablet n
Tablet 1 LEADER
Tablet 3 FOLLOWER
Tablet Server W
Tablet 1 FOLLOWER
Tablet 2 FOLLOWER
Tablet Server X
Tablet 1 FOLLOWER
Tablet 2 FOLLOWER
Tablet 3 LEADER
Tablet Server Y
Tablet 2 LEADER
Tablet 3 FOLLOWER
Tablet Server Z

Tablet

- 类LSM(HBase):
  - 每个Tablet包含一个MemRowSet和多个DiskRowSet；新插入的数据存储在MemRowSet中，定期flush成DiskRowSet
  - 不同于LSM，每一个Row只存在于一个RowSet中
- RowSet
  - RowSet内有序，RowSet间无序，不同RowSet所包含的key range允许重叠
  - MemRowSet内部使用B树行存储，DiskRowSet使用列存储

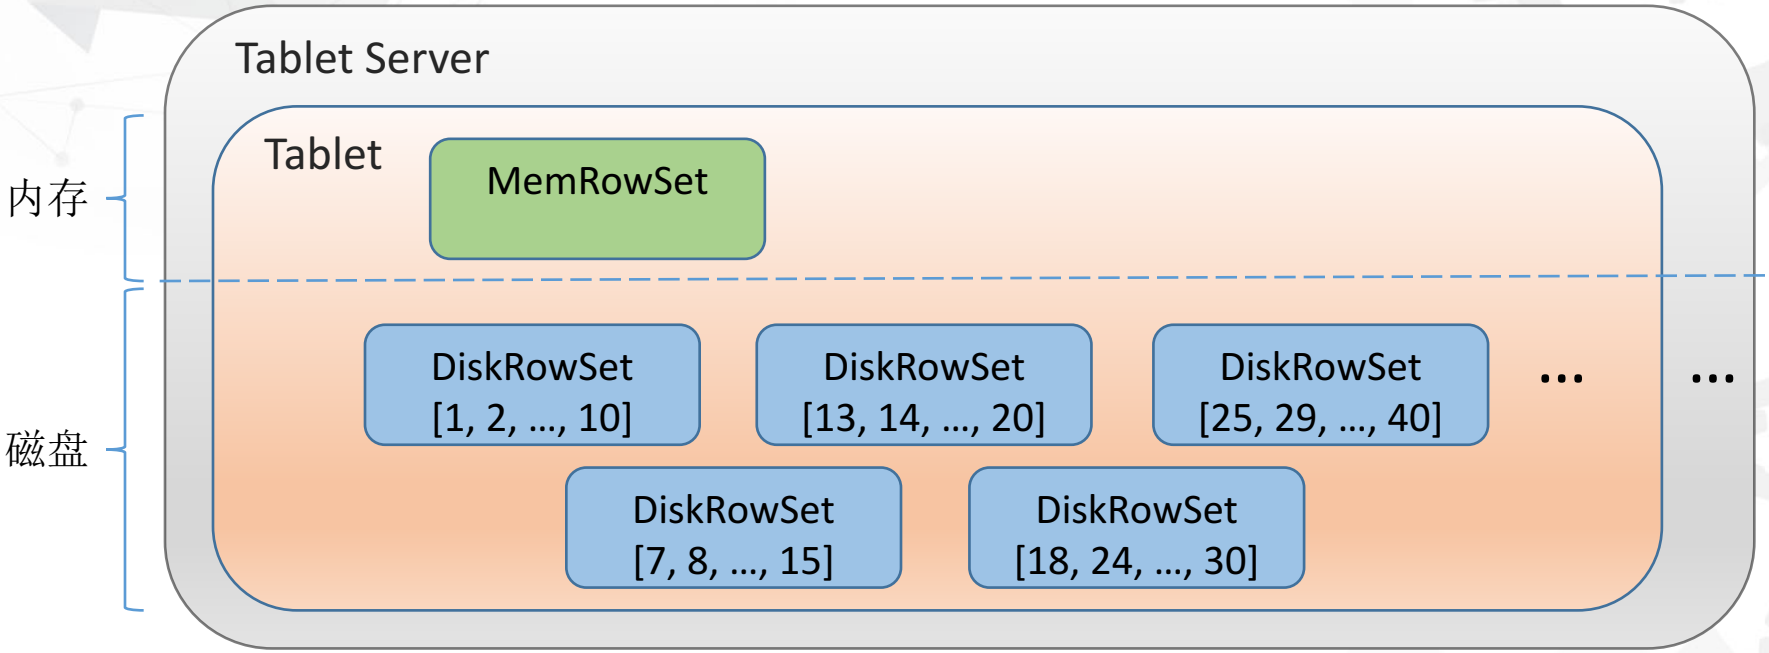

MVCC

- MVCC
  - 对每一行都保存多个版本
- MVCC所提供的能力
  - Snapshot读
  - 历史读
  - 增量备份
  - 同一个Tablet内多行写的原子性
- 一个写操作的执行步骤
  - leader收到写请求，获得要写的行锁
  - 为写操作分配timestamp
  - 通过raft协议备份写操作
  - 真正对行数据做更改
  - 更改timestamp为committed，对外可见

MVCC & 数据存储

Insert：

- 所有新插入的数据均存储在MemRowSet中
- 插入前使用interval tree和bloom filter检查是否已存在

Update/Delete：

- 对MemRowSet中的数据更新，Flush后形成Undo Records
- 对DiskRowSet中的数据更新，存储在DeltaMemStore中，Flush后形成Redo Records

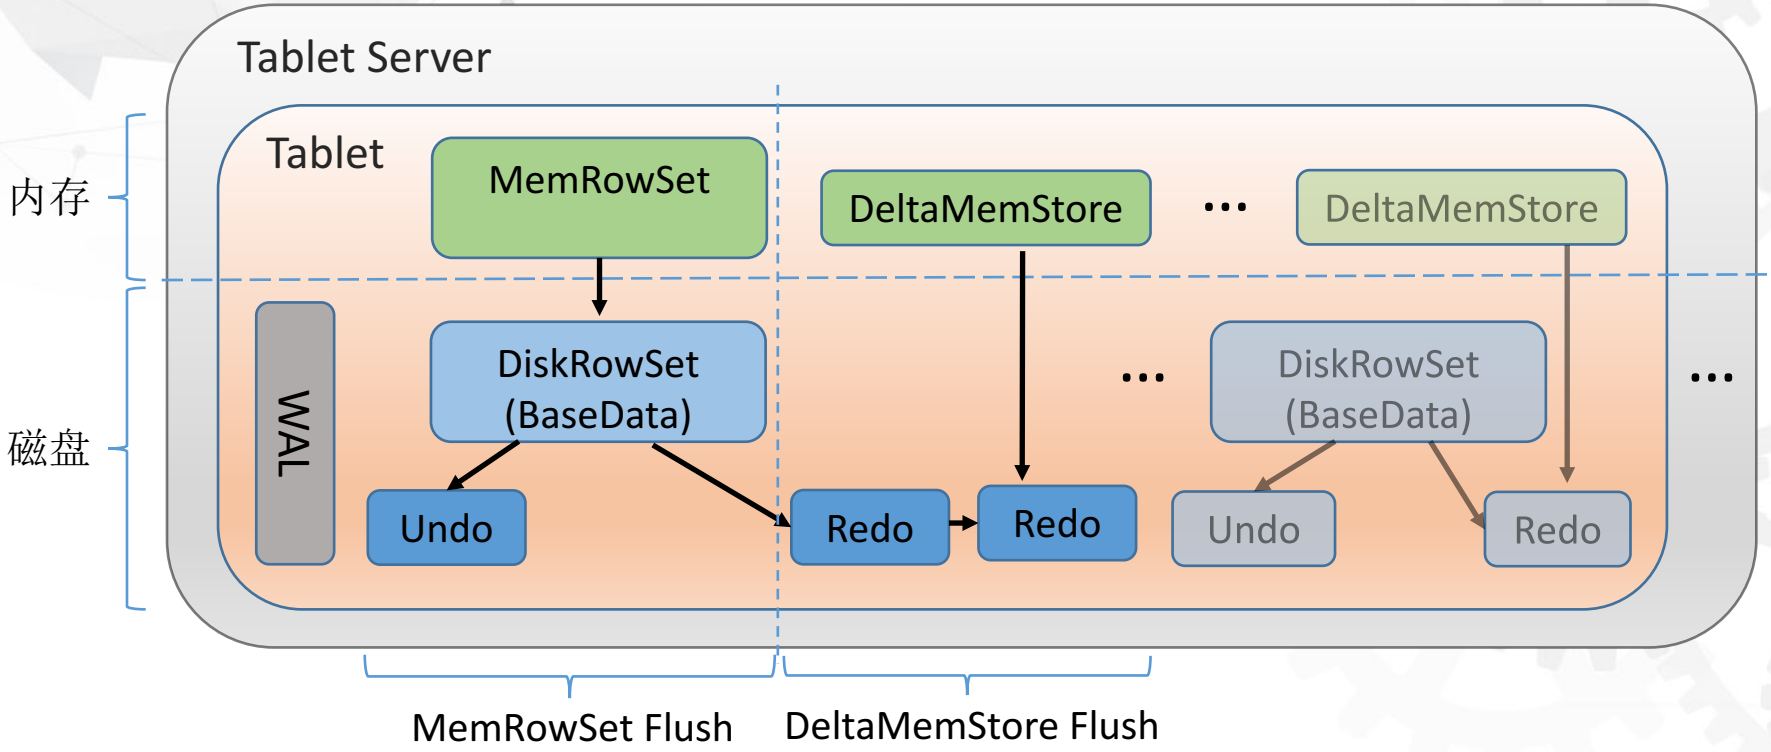

Flush示例

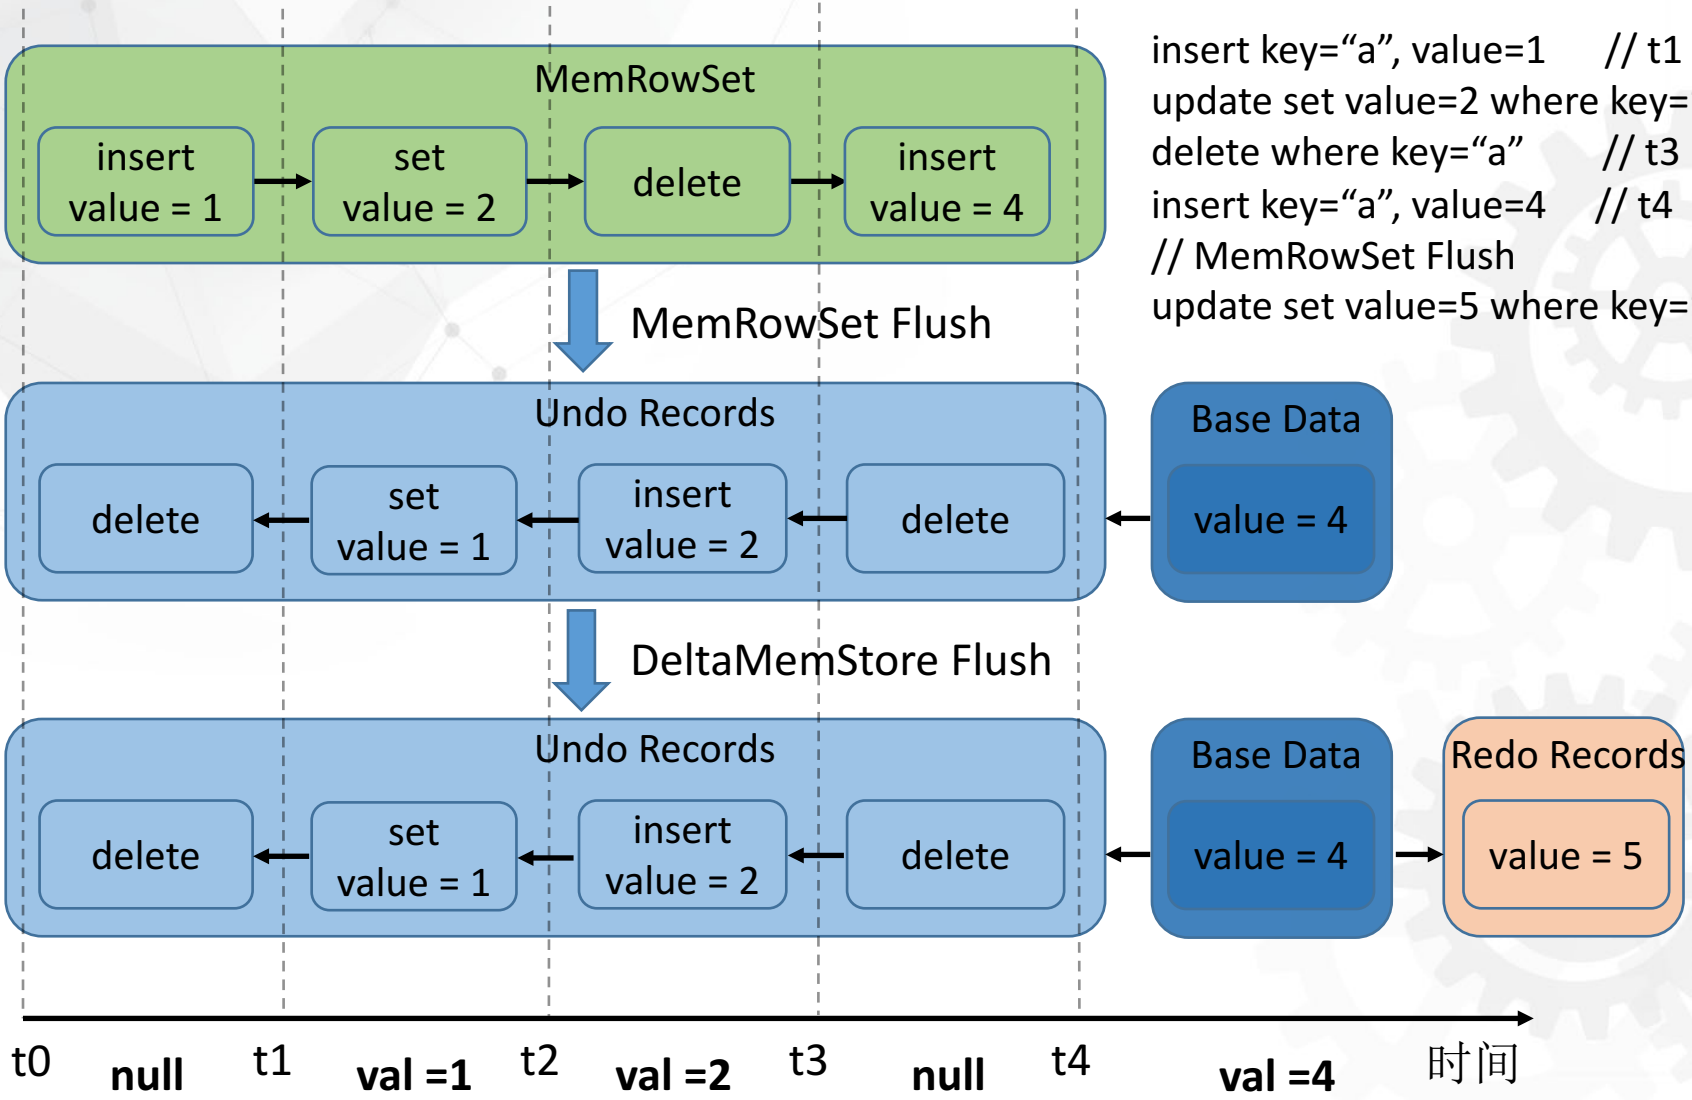


```
insert key="a", value=1      // t1
update set value=2 where key="a"  // t2
delete where key="a"         // t3
insert key="a", value=4      // t4
// MemRowSet Flush
update set value=5 where key="a"  // t5
```

Delta Compaction

Minor Compaction:

- 减少Redo文件的数量，增加读效率

Major Compaction:

- 只读Base Data，节省apply delta的操作

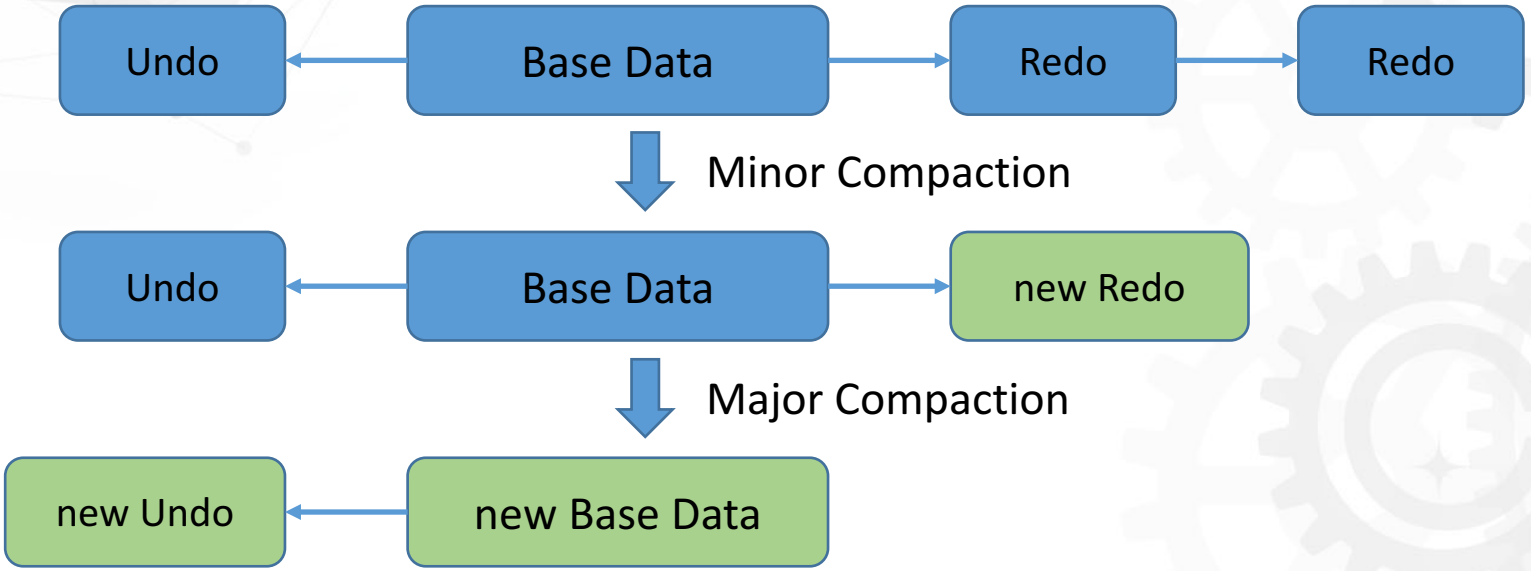

DiskRowSet Compaction

- 减少DiskRowSet间的重叠情况
  - 写操作时减少需要查询的DiskRowSet
  - 读操作读取更少的文件，增加读效率
- 后台线程在空闲时做小规模Compaction
- 在设计表的schema时，需要考虑尽量进行顺序写，以减少后期Compaction的操作。不要使用id做为主键的第一列。

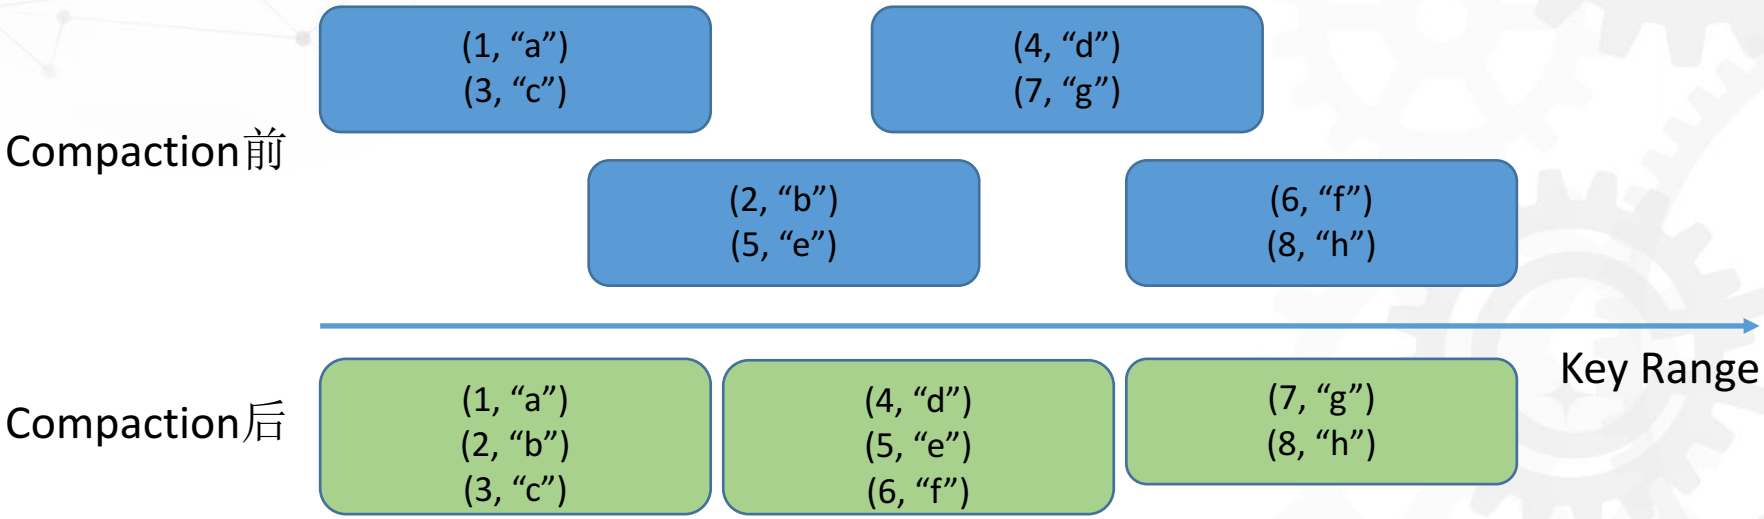

Integration with Spark

Kudu为Spark带来了什么？

- 实时数据的快速分析
- 谓词下推，加速查询
- 基于主键索引的快速查询
- Update和Delete的支持

Spark为Kudu带来了什么？

- 更简单的数据操作方式

NoSQL API

Write

```
KuduTable table = client.openTable("my_table");
KuduSession session = client.newSession();
Insert ins = table.newInsert();
ins.getRow().addString("metric", "load-avg.1sec");
ins.getRow().addDouble("value", 0.05);
session.apply(ins);
session.flush();
```

Read

```
KuduScanner scanner = client.newScannerBuilder(table)
  .setProjectedColumnNames(Lists.of("value"))
  .build();
while (scanner.hasMoreRows()) {
  RowResultIterator batch = scanner.nextRows();
  while (batch.hasNext()) {
    RowResult result = batch.next();
    System.out.println(result.getDouble("value"));
  }
}
```

Spark DataFrame

```
// spark-shell --packages org.apache.kudu:kudu-spark_2.10:1.2.0
// Import kudu datasource
import org.kududb.spark.kudu._
val kuduDataFrame = sqlContext.read.options(
   Map("kudu.master" -> "master1,master2,master3",
      "kudu.table" -> "my_table_name")).kudu

// Then query using Spark data frame API
kuduDataFrame.select("id").filter("id" >= 5).show()
// (prints the selection to the console)

// Or register kuduDataFrame as a table and use Spark SQL
kuduDataFrame.registerTempTable("my_table")
sqlContext.sql("select id from my_table where id >= 5").show()
// (prints the sql results to the console)
```

KuduRDD的实现

- getPartitions
  - 根据下推的predicate获得需要访问的tablet list
  - 每个tablet均包装为一个Partition
- getPreferredLocations
  - 每个tablet的replica locations
- execute
  - 新建KuduScanner进行数据扫描

```
override protected def getPartitions: Array[Partition] = {
  val builder = kuduContext.syncClient
                           .newScanTokenBuilder(table)
                           .batchSizeBytes(batchSize)
                           .setProjectedColumnNames(projectedCols.toSeq.asJava)
                           .cacheBlocks(true)

  for (predicate <- predicates) {
    builder.addPredicate(predicate)
  }
  val tokens = builder.build().asScala
```

SparkSQL on Kudu

目标：

- 和SparkSQL on HDFS提供一致的对外接口（数据库/表/SQL）
- 更好的利用Kudu提供的能力，如update/delete
- 增加内部需要的功能，例如动态分区管理，权限控制等

实现：

- 修改SparkSQL语法
- 增加KuduExternalCatalog，直接使用KuduClient获得表的元数据信息
- 新建Kudu系统表，存储内部功能需要的其他元信息

SparkSQL on Kudu

```
// 创建表
CREATE TABLE kudu_test (
   year INT WITH (key=true),
   id INT WITH (key=true),
   msg STRING )
PARTITIONED BY
HASH (id) INTO 10 BUCKETS,
RANGE (year) RANGE BETWEEN ((2015),(2016));

// 增删分区
ALTER TABLE kudu_test ADD PARTITION ((2016), (2017));
ALTER TABLE kudu_test DROP PARTITION ((2015), (2016));

// 展示Range分区
SHOW PARTITIONS kudu_test;

// Update/Delete
UPDATE kudu_test SET msg="b" WHERE year=2015 AND id=1;
DELETE FROM kudu_test WHERE year=2015 AND id=1;
```

Twitter实时数据

13M数据

当前时间

最新记录

Adhoc查询

```
0: jdbc:hive2://10.[redacted]:16000/default> SELECT count(*) FROM twitter;
+-----------+--+
| count(1)  |
+-----------+--+
| 13472982  |
+-----------+--+
1 row selected (0.396 seconds)
0: jdbc:hive2://10.[redacted]:16000/default> SELECT current_timestamp();
+--------------------------+--+
|   current_timestamp()    |
+--------------------------+--+
| 2017-05-03 23:47:35.131  |
+--------------------------+--+
1 row selected (0.068 seconds)
0: jdbc:hive2://10.[redacted]:16000/default> SELECT created_at, text, user_name FROM twitter ORDER BY created_ts DESC
 LIMIT 1;
+----------------------+-----------------------------------------------------------------------------------------------
-------+-------------+--+
|      created_at      |                                                  text
       |  user_name  |
+----------------------+-----------------------------------------------------------------------------------------------
-------+-------------+--+
| 2017-05-03 23:47:32  | RT @minghawt: I can't believe the royal princes of Korea are coming back https://t.co/tLVk4
2tGw2  | kongbiitch  |
+----------------------+-----------------------------------------------------------------------------------------------
-------+-------------+--+
1 row selected (4.986 seconds)
0: jdbc:hive2://10.[redacted]:16000/default> SELECT user_location, count(*) AS tweets_num FROM twitter WHERE created_
ts>unix_timestamp()-3600 AND instr(text, "trump")!=0 AND instr(user_location, "USA")!=0 GROUP BY user_location ORDER
 BY tweets_num DESC LIMIT 5;
+------------------+-------------+--+
|  user_location   | tweets_num  |
+------------------+-------------+--+
| USA              | 34          |
| California, USA  | 28          |
| Florida, USA     | 24          |
| New Jersey, USA  | 22          |
| Texas, USA       | 18          |
+------------------+-------------+--+
5 rows selected (4.148 seconds)
0: jdbc:hive2://10.[redacted]:16000/default>
```

小米的实时数据仓库

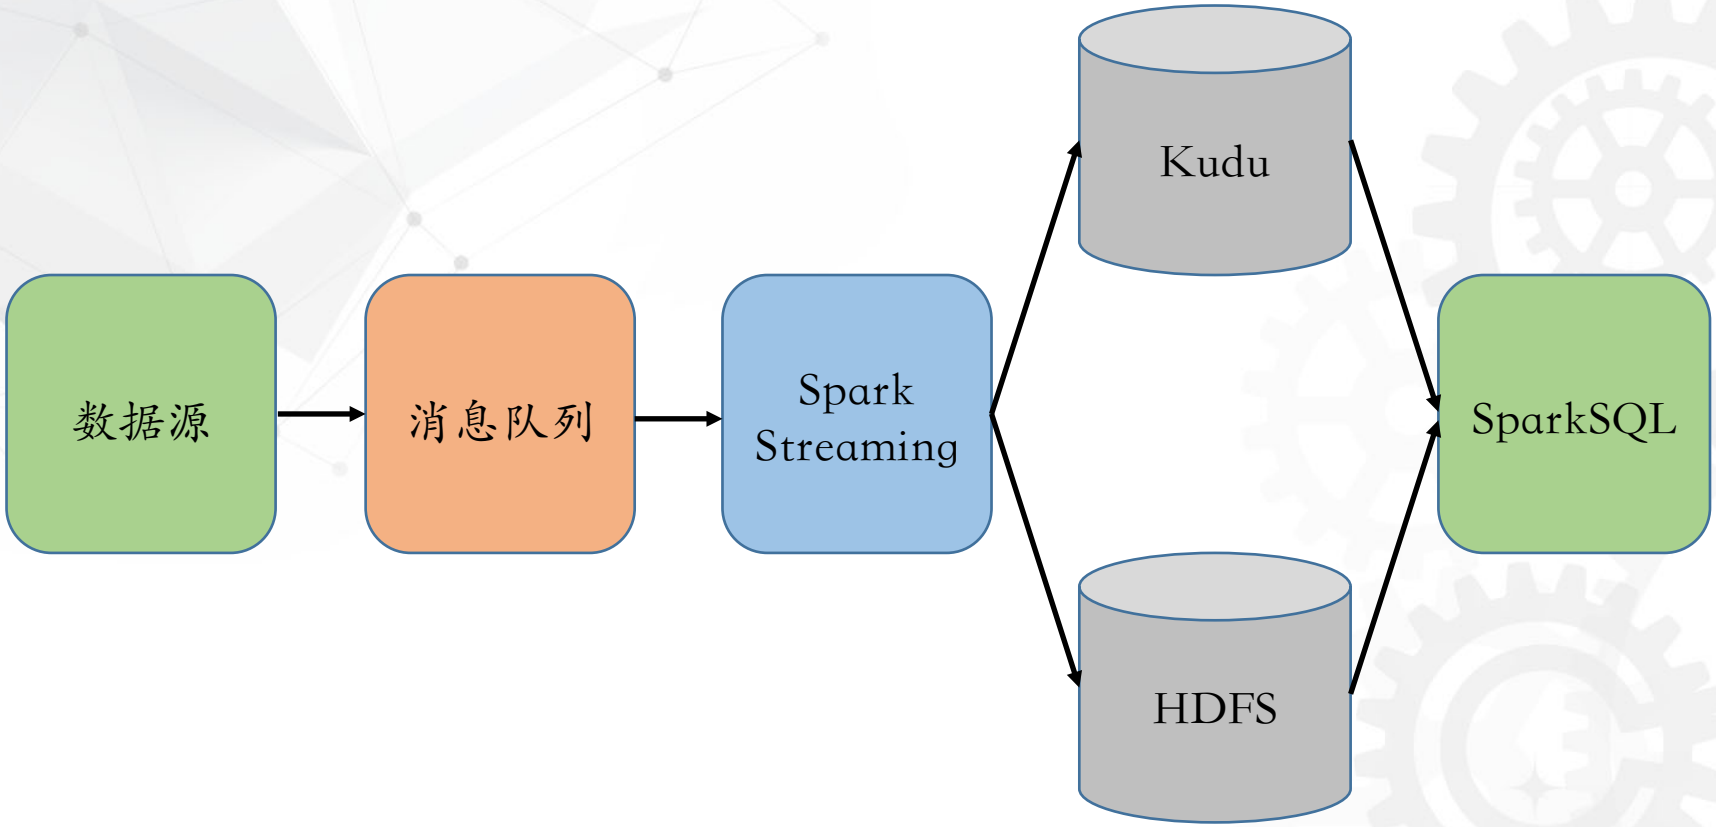

限制 & Roadmap

限制：

- 没有自增主键
- 不支持嵌套结构
- 监控工具不完善
- Load balance

Roadmap：

- 运维上，增强运维工具的功能（错误恢复，问题诊断）
- 性能上，和查询引擎的深度优化（runtime filter），优化批量导入的性能
- 功能上，完善安全机制，细粒度的权限管理，和Sentry的整合

Kudu vs 流式计算

流式计算的一些局限：

- 预计算固定的指标，Ad-hoc查询能力较弱
- 复杂的查询难以支持（大表join）
- 精度要求（TopN，count(distinct)）
- 存在时间窗口
- 容错状态保存，依赖于外部存储，难以开发

Kudu vs Druid

数据精度不同：

- Druid对数据进行预聚合，不保存原始数据

内部存储不同：

- 均是列存储，但Druid内部使用bitmap倒排表，Kudu使用bitshuffle等encoding方式

应用场景不同：

- Druid更适合做在线指标的实时统计等工作，Kudu适合实时的分析类查询

查询方式不同：

- Druid有自己的查询引擎，尚不支持join；Kudu依靠Impala/SparkSQL，对SQL的支持更加完整

查询性能不同：

- Druid查询的是OLAP Cube，速度更快；Kudu需要扫描原始数据，可支持的查询更灵活

THANKS

SequeMedia 盛拓传媒 IT168.com ITPUB ChinaUnix